

Análise de Hiperparâmetros em Sistemas de Geração Aumentada por Recuperação Aplicado ao Acervo do Ministério Público do Estado do Espírito Santo

Hyperparameter Analysis in Retrieval-Augmented Generation Systems Applied to Ministério Público do Estado do Espírito Santo Corpus

Heitor Coitinho Quarteazani¹ and Diego Roberto Colombo Dias¹

¹Departamento de Estatística – Universidade Federal do Espírito Santo (UFES)

2025

Resumo

Este trabalho de pesquisa propõe uma metodologia fundamentada em Planejamento de Experimentos (*Design of Experiments*) para analisar e otimizar os hiperparâmetros de um sistema de *Retrieval-Augmented Generation* aplicado ao acervo normativo do Ministério Público do Estado do Espírito Santo. O objetivo central é, entre os fatores críticos, como a estratégia de segmentação de documentos (*chunking*), o volume de contexto recuperado (k) e a escolha do *Large Language Model* utilizado, identificar aqueles que apresentam impacto estatisticamente significativo na qualidade das respostas geradas. A avaliação utiliza o paradigma *LLM-as-a-Judge* com o suporte do *framework* de Avaliação de Geração Aumentada por Recuperação (*Retrieval Augmented Generation Assessment*). Devido à natureza não-paramétrica dos dados, a análise estatística é conduzida via Transformação de Postos Alinhados (*Aligned Rank Transform*). Os resultados revelam que os hiperparâmetros têm impacto significativo na qualidade da resposta.

Palavras-chave: Geração Aumentada por Recuperação (RAG), Desenho de Experimentos (DoE), Otimização de Hiperparâmetros, *Large Language Model* (LLM), *Aligned Rank Transform* (ART), Ragas, MPES, LLM-as-a-Judge.

Abstract. This research paper proposes a methodology based on *Design of Experiments* to analyze and optimize the hyperparameters of a *Retrieval-Augmented Generation* system applied to the normative corpus of the Ministério Público do Estado do Espírito Santo. The central objective is to identify which critical factors, such as the document segmentation strategy (*chunking*), the volume of retrieved context (k), and the choice of the *Large Language Model*, have a statistically significant impact on the quality of the generated responses. The evaluation employs the *LLM-as-a-Judge* paradigm supported by the *Retrieval Augmented Generation Assessment* framework. Due to the non-parametric nature of the data, the statistical analysis is conducted via the *Aligned Rank Transform*. The results reveal that the hyperparameters have a significant impact on the responses' quality.

Keywords: Retrieval-Augmented Generation (RAG), Design of Experiments (DoE), Hyperparameter Optimization, Large Language Model (LLM), Aligned Rank Transform (ART), Ragas, MPES, LLM-as-a-Judge.

1 Introdução

O cenário que motivou este estudo originou-se de uma limitação operacional crítica no Ministério Público do Estado do Espírito Santo (MPES). A instituição possui um vasto acervo de atos normativos e portarias digitalizados [MPES, 2026]. No entanto, o acesso a esse capital informacional era restringido pela ineficácia das ferramentas de busca disponíveis, limitadas à correspondência textual exata. Essa carência técnica tornava a recuperação da informação lenta e dependente do conhecimento tácito dos servidores sobre a estrutura dos documentos, dificultando a consulta exploratória.

Para superar essa barreira de acessibilidade e democratizar o acesso ao acervo, foi proposto o desenvolvimento de uma assistente virtual, batizada de **Fabi**, em homenagem a uma servidora reconhecida pela proficiência na navegação manual desses arquivos. Para operacionalizar a assistente e garantir que as respostas fossem fundamentadas nos documentos oficiais, mitigando o risco da geração de fatos plausíveis, porém falsos, fenômeno conhecido como alucinação [Ji et al., 2023], optou-se pela arquitetura de Geração Aumentada por Recuperação (*Retrieval-Augmented Generation* - RAG) [Lewis et al., 2020].

A macroarquitetura da assistente Fabi integra quatro componentes fundamentais: uma interface de usuário, um motor de orquestração, um banco de dados vetorial e um modelo de linguagem gerador. O fluxo operacional do sistema, detalhado na Figura 1, segue uma lógica de processamento em etapas coordenadas.




Figura 1: Fluxo de funcionamento e componentes da arquitetura RAG da assistente Fabi.

O funcionamento inicia-se com a interação do usuário via interface Gradio (1º), que encaminha a requisição ao orquestrador desenvolvido em FastAPI. O orquestrador envia a pergunta e a configuração de hiperparâmetros definidas ao motor RAG (2º). O motor faz a recuperação de documentos relevantes e envia o contexto e a pergunta para o gerador (ChatGPT) (3º). A resposta gerada é enviada de volta para o orquestrador (4º), e por fim é exibida para o usuário pela interface (5º).

A arquitetura RAG permite conectar a fluidez dos Grandes Modelos de Linguagem (Large Language Models - LLMs) a uma base de conhecimento externa e confiável [Gupta et al., 2024]. Contudo, a eficácia de um sistema RAG não é garantida apenas pela sua implementação; o desempenho é altamente sensível a hiperparâmetros de configuração, como a estratégia de segmentação dos textos (*chunking*) e o volume de contexto recuperado (k). Configurações subótimas podem levar a respostas irrelevantes ou perda de informação crítica [Wang et al., 2024].

1.1 Objetivos

O objetivo geral deste trabalho foi desenvolver e aplicar uma metodologia de Desenho de Experimentos (*Design of Experiments* - DoE), para analisar sistematicamente e otimizar os hiperparâmetros de um sistema RAG aplicado ao acervo do MPES. Buscou-se identificar os fatores que exercem influência estatisticamente significativa na qualidade das respostas geradas.

Para alcançar o objetivo geral, os seguintes objetivos específicos foram perseguidos:

- Avaliar o impacto de quatro estratégias de *chunking* ao comparar abordagens recursivas e semânticas.
- Comparar a eficácia de métodos de recuperação vetorial, lexical e híbrida.
- Analisar o número de documentos recuperados (k) e buscar o ponto de equilíbrio entre contexto e ruído.
- Quantificar o ganho de desempenho entre LLMs de diferentes classes de complexidade.

1.2 Justificativa

A escolha da arquitetura RAG fundamenta-se nas limitações intrínsecas das abordagens alternativas para o domínio jurídico. Sistemas de busca puramente lexicais (baseados em palavras-chave) falham em capturar a semântica de consultas complexas, onde o usuário busca pelo conceito da norma e não necessariamente pelos termos exatos contidos no texto. Por outro lado, o uso isolado de LLMs seria inviável devido à impossibilidade de retreinamento contínuo com dados privados e, principalmente, ao risco inaceitável de alucinações. O RAG mitiga esses problemas ao ancorar a geração de texto em evidências recuperadas diretamente do acervo do MPES, garantindo rastreabilidade e precisão factual.

Cientificamente, este trabalho justifica-se pela aplicação do DoE no contexto de sistemas RAG. Enquanto a maioria das implementações comerciais ajusta hiperparâmetros de maneira empírica ou via tentativa e erro, esta pesquisa oferece uma validação quantitativa rigorosa. A utilização do DoE permite isolar quais fatores possuem impacto estatisticamente significativo na qualidade da resposta, substituindo o empirismo por evidência estatística [Montgomery, 2017, Wang et al., 2024].

Institucionalmente, o trabalho justifica-se por transformar um acervo documental estático e inacessível em uma ferramenta dinâmica de suporte à decisão.

2 Fundamentação Teórica

Este capítulo estabelece o arcabouço teórico necessário para a otimização proposta, situando o estudo na interseção entre Processamento de Linguagem Natural (NLP) [Jurafsky and Martin, 2024], Recuperação de Informação (IR) [Manning et al., 2008] e Estatística Experimental [Montgomery, 2017]. A exposição segue uma estrutura lógico-constructiva: inicia-se com a representação matemática do texto em espaços vetoriais, avançando para a modelagem estocástica de sequências por meio da arquitetura *Transformer*. Em seguida, detalha-se a engenharia de sistemas RAG, abrangendo estratégias de segmentação e algoritmos de busca híbrida. Por fim, definem-se os protocolos de avaliação automatizada e detalha-se o referencial analítico, fundamentado no delineamento Fatorial Completo e no método não-paramétrico Transformação de Postos Alinhados (*Aligned Rank Transform* - ART) [Wobbrock et al., 2011a], que viabilizará a investigação quantitativa dos hiperparâmetros.

2.1 Representação Vetorial de Texto

Para que modelos estatísticos processem linguagem natural, é necessário converter dados simbólicos (texto) em representações numéricas operáveis. Este processo ocorre em duas etapas fundamentais: a discretização do texto em *tokens* e a subsequente projeção destas unidades em um espaço vetorial contínuo (*embeddings*).

2.1.1 Tokenização

A tokenização é o processo determinístico de segmentação de uma sequência de caracteres em unidades semânticas mínimas. Formalmente, dado um corpus C , constrói-se um vocabulário V finito onde cada *token* único t é mapeado para um índice inteiro $i \in \{1, \dots, |V|\}$. Em arquiteturas modernas, prioriza-se a tokenização por subpalavras (*Subword Tokenization*), que equilibra a granularidade entre caracteres individuais e palavras inteiras. Essa abordagem permite que o modelo componha representações para termos raros ou neologismos através da aglutinação de morfemas conhecidos [Jurafsky and Martin, 2024, Vaswani et al., 2017]. Para a gestão eficiente e em larga escala desses dicionários, empregam-se algoritmos de codificação como o *Byte Pair Encoding* (BPE), frequentemente implementados em bibliotecas de alta performance como o *tiktoken* [OpenAI, 2023].

2.1.2 Embeddings e Espaço Latente

A simples indexação numérica de *tokens* é insuficiente para capturar propriedades e relações semânticas. Para superar essa limitação, utiliza-se o conceito de *Word Embeddings*, que consiste em representar cada termo como um vetor denso $v \in \mathbb{R}^d$ em um espaço latente de alta dimensionalidade (tipicamente com d variando entre 768 e 4096). Essa representação [Bengio et al., 2003, OpenAI, 2024] fundamenta-se na Hipótese Distribucional de Harris [1954], a qual postula que palavras ocorrentes em contextos similares tendem a possuir significados análogos.

Em termos geométricos, o treinamento de um LLM consiste em ajustar essas representações de modo que a proximidade espacial entre dois vetores reflita diretamente a sua similaridade de cosseno. Conforme ilustrado de forma didática na Figura 2, termos do domínio jurídico, como “Furto” e “Subtração”, agrupam-se em uma região do espaço e distanciam-se estruturalmente de conceitos pertencentes a outros domínios, como o culinário.




Figura 2: Representação simplificada de um espaço vetorial em $\mathbb{R}^2$.

2.1.3 Similaridade de Cosseno

Para quantificar a proximidade entre dois vetores nesse espaço latente e, consequentemente, avaliar sua afinidade semântica, estabelece-se uma métrica de distância vetorial [Manning et al., 2008]. Em sistemas de processamento de linguagem natural e recuperação de informação, a métrica amplamente adotada é a similaridade de cosseno. Diferentemente da distância Euclidiana (L_2), que mensura a magnitude absoluta entre os pontos e pode ser distorcida pela extensão do texto (gerando vetores muito longos), a similaridade de cosseno avalia estritamente a orientação angular entre dois vetores não nulos u e v . Matematicamente, ela é definida pelo produto interno dos vetores normalizados, garantindo que textos de tamanhos diferentes, mas com o mesmo direcionamento temático, sejam identificados como similares:

$$\text{sim}(u, v) = \frac{u \cdot v}{\|u\| \|v\|} = \frac{\sum_{i=1}^d u_i v_i}{\sqrt{\sum_{i=1}^d u_i^2} \sqrt{\sum_{i=1}^d v_i^2}}. \quad (1)$$

2.2 A Arquitetura Transformer

Para compreender a eficácia de um sistema de *Retrieval-Augmented Generation* (RAG), é necessário primeiro mapear como o modelo de linguagem processa a informação. Toda a fundação estrutural descrita nesta subseção baseia-se no trabalho seminal de Vaswani et al. [2017], que introduziu a arquitetura *Transformer*. Este modelo tornou-se a base dos LLMs ao abandonar o processamento sequencial tradicional em favor de um processamento altamente paralelo. O fluxo de dados pode ser compreendido pelas funções de seus blocos principais:




Figura 3: Arquitetura do Modelo Transformer baseada em Vaswani et al. [2017].

1. **Vetores de Entrada, Vetores de Saída e Codificação Posicional:** O processo inicia-se convertendo *tokens* em vetores contínuos. É crucial diferenciar os dois fluxos de dados que alimentam a arquitetura:

- **Vetores de Entrada (*Inputs*):** Inseridos na base do Codificador, representam o contexto externo fornecido ao modelo (ex: o *prompt* do usuário somado aos documentos recuperados pelo RAG).
- **Vetores de Saída (*Outputs*):** Inseridos na base do Decodificador, representam os *tokens* que o próprio modelo já gerou nas etapas anteriores da resposta (deslocados à direita para manter o caráter autorregressivo).

Como o modelo não possui recorrência para rastrear a ordem das palavras, uma Codificação Posicional é somada a ambos os vetores, injetando matematicamente a posição de cada *token* na sequência.

2. **O Codificador (*Encoder*):** Sua função é mapear os vetores de entrada em uma representação rica em contexto. Ele processa toda a sequência simultaneamente, cruzando as informações entre todos os *tokens* fornecidos para extrair a semântica global da frase antes de enviá-la ao decodificador.
3. **O Decodificador (*Decoder*):** Seu papel é gerar a resposta final. Ele recebe as representações processadas pelo codificador e as cruza com os vetores de saída (o que já foi escrito). Para evitar que o modelo “veja o futuro” durante o treinamento, o decodificador utiliza um mascaramento que o obriga a olhar apenas para os *tokens* do passado.
4. **Geração de Probabilidades (Linear e *Softmax*):** A saída final do decodificador é um vetor matemático contínuo. Uma camada Linear projeta esse vetor para a exata dimensão do vocabulário da IA. Imediatamente após, a função *softmax* converte esses números em uma distribuição de probabilidades. O próximo *token* do texto é então amostrado a partir desta distribuição.

2.2.1 O Mecanismo de Atenção

A capacidade do modelo de processar os longos contextos fornecidos por um sistema RAG reside especificamente no interior do codificador e decodificador: o mecanismo de atenção.

Uma função de atenção mapeia uma consulta (*query*) e um conjunto de pares chave-valor (*key-value*) para uma saída. Na arquitetura *Transformer*, isso é implementado através da Atenção de Produto Escalar Escalado (*Scaled Dot-Product Attention*):

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2)$$

Nesta formulação:

- **Consultas (*Q*) e Chaves (*K*):** O modelo calcula o produto escalar entre a matriz de consultas e a matriz de chaves. No contexto de um sistema RAG, isso atua como uma métrica de compatibilidade: o modelo avalia matematicamente o quão relevante cada palavra do contexto recuperado (chaves) é para a pergunta em processamento (consulta). O fator $\sqrt{d_k}$ escala os valores para evitar que o crescimento do produto escalar prejudique a estabilidade matemática do modelo.
- **Valores (*V*) e a Função *Softmax*:** Ao aplicar a função *softmax* sobre essas compatibilidades, o modelo gera um vetor de pesos distributivos. A matriz de Valores (*V*), que contém o conteúdo semântico real, é então multiplicada por esses pesos.

O resultado prático dessa operação é a atribuição de um peso quase nulo às partes irrelevantes do texto, forçando a capacidade computacional a focar exclusivamente nos trechos de informação que importam. É esta filtragem dinâmica que permite ao LLM assimilar um documento externo inserido pelo RAG e sintetizar uma resposta fundamentada.

2.2.2 O LLM como Estimador de Probabilidade e a Alucinação

Com a conversão dos valores em probabilidades na camada de saída, o LLM atua fundamentalmente como um estimador de probabilidade condicional P_θ [Bengio et al., 2003]. O processo de geração de texto (inferência) consiste na aplicação iterativa da regra da cadeia, onde o próximo *token* w_t é amostrado condicionado ao histórico de contexto C :

$$w_t \sim P(w_t|C; \theta). \quad (3)$$

Neste cenário estatístico, o fenômeno da “alucinação” ocorre quando o modelo atribui uma alta massa de probabilidade a uma sequência de *tokens* que é sintaticamente fluida, porém factualmente incorreta ou desconectada da realidade [Ji et al., 2023]. O sistema RAG atua exatamente na alteração do contexto C , injetando informações recuperadas para redistribuir as probabilidades do modelo em direção a fatos ancorados, mitigando assim a alucinação.

2.2.3 Controle de Entropia via Temperatura

A transformação final em uma distribuição de probabilidades através da função *softmax* introduz um hiper-parâmetro crucial: a Temperatura (T). Estatisticamente, a temperatura atua como um mecanismo de controle da entropia da distribuição, governando o balanço entre o determinismo e a aleatoriedade durante a amostragem.

Matematicamente, a função *softmax* com o parâmetro de temperatura acoplado é definida como:

$$P(w_i) = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)} \quad (4)$$

onde z_i representa a saída da camada linear (*logit*) correspondente ao *token* i do vocabulário, e T é um valor real estritamente positivo. A variação de T altera o formato da distribuição:

- **Baixa Temperatura** ($T \rightarrow 0$): A diferença entre os maiores *logits* é amplificada exponencialmente, colapsando a distribuição em direção ao *token* mais provável. O modelo torna-se conservador e quase determinístico. No escopo de um sistema RAG, esta é a configuração ideal, pois minimiza a variância estocástica e força o modelo a gerar respostas ancoradas estritamente no contexto recuperado.
- **Temperatura Neutra** ($T = 1$): A equação retorna à sua forma *softmax* padrão, refletindo as probabilidades originais aprendidas pela rede.
- **Alta Temperatura** ($T > 1$): A distribuição é achatada, aproximando-se de uma distribuição uniforme. Isso aumenta a diversidade lexical, mas eleva significativamente a probabilidade de o modelo amostrar informações incorretas e alucinar fatos não contidos no contexto.

Desta forma, a calibração da temperatura ajusta a decodificação da linguagem às exigências de precisão e factualidade inerentes ao RAG.

2.3 Estratégias de Segmentação

A indexação vetorial exige a discretização de documentos longos em unidades menores, denominadas *chunks*. A definição da granularidade dessa discretização envolve um compromisso crítico entre a densidade de informação relevante (sinal) e a inclusão de informações periféricas irrelevantes (ruído).

Conforme Zhang et al. [2024a], essa segmentação impacta diretamente a probabilidade de recuperação $P(Z|q)$ de um trecho Z dada uma consulta q , manifestando-se de duas formas antagônicas:

- **Granularidade Fina (*Small Chunks*)**: Maximiza a proporção de sinal e a similaridade de cosseno ao isolar fatos específicos. Contudo, corre o risco de fragmentar o contexto, rompendo correferências e unidades de raciocínio essenciais para a interpretação correta da informação.
- **Granularidade Grossa (*Large Chunks*)**: Preserva o contexto global e as dependências semânticas. No entanto, o vetor resultante torna-se uma média semântica de um texto extenso, diluindo a especificidade da informação buscada. Além de prejudicar a recuperação vetorial, o excesso de ruído contextual degrada a capacidade de atenção do modelo de linguagem durante a síntese da resposta [Liu et al., 2023].

Para equilibrar essa balança e otimizar a recuperação, a literatura propõe duas abordagens principais de segmentação. A primeira foca em regras mecânicas, enquanto a segunda utiliza a própria distribuição semântica dos dados.

2.3.1 Segmentação Recursiva e Janelas Deslizantes

A abordagem padrão discretiza o texto baseando-se em delimitadores sintáticos (parágrafos, quebras de linha) e um limite fixo de caracteres L .

A principal limitação teórica deste método é a imposição de fronteiras arbitrárias que podem seccionar sentenças ou argumentos lógicos nas bordas (*boundary loss*). Para mitigar a perda de informação nessas extremidades, aplica-se a técnica de Janela Deslizante com Sobreposição (*Overlap*). Seja C_i o i -ésimo *chunk* de comprimento L e O o tamanho da sobreposição, o início do *chunk* C_{i+1} é deslocado por $L - O$ em relação a C_i .

A Figura 4 ilustra essa redundância intencional. O parâmetro $O > 0$ garante a continuidade semântica e assegura que termos localizados no final de um segmento possuam contexto à direita na janela subsequente. Neste trabalho, definiram-se empiricamente janelas com O proporcional a 20% de L .

Contudo, mesmo com a sobreposição, a segmentação recursiva permanece “cega” ao significado do texto. Para contornar essa falha estrutural, modelos mais avançados adotam estratégias estatísticas de corte.




Figura 4: Processo de segmentação com janela deslizante.

2.3.2 Segmentação Semântica

Em contraste com a métrica fixa de caracteres, a Segmentação Semântica propõe que as quebras ocorram apenas quando há uma mudança significativa de tópico. O método baseia-se na premissa geométrica de que mudanças de assunto correspondem a grandes distâncias angulares no espaço vetorial.

O algoritmo opera calculando a similaridade semântica $\text{sim}(s_t, s_{t+1})$ entre sentenças sequenciais. Formalmente, define-se uma fronteira de *chunk* no índice t se a dissimilaridade exceder um limiar crítico τ :

$$1 - \text{sim}(s_t, s_{t+1}) > \tau, \quad (5)$$

onde τ é tipicamente definido como um percentil da distribuição de distâncias do documento.

Conforme ilustrado na Figura 5, esta abordagem agrupa sentenças semanticamente coesas (como S_1 , S_2 e S_3), minimizando a variância intra-*chunk*. A transição entre S_3 e S_4 apresenta uma similaridade (0.21) consideravelmente inferior ao limiar definido (neste exemplo, $\tau = 0.5$). Essa queda brusca provoca a quebra geométrica do documento e marca o início de um novo *chunk*. Ao detectar essa fronteira natural do tópico e realizar o corte estrutural, o sistema teoricamente maximiza a relevância do contexto recuperado, evitando a inserção de assuntos desconexos no *prompt* do modelo gerador.




Figura 5: Abstração do processo de Segmentação Semântica.

2.4 Recuperação de Informação

A arquitetura RAG depende intrinsecamente da capacidade de recuperar um subconjunto de documentos $Z \subset D$ que seja semanticamente relevante para a consulta do usuário q . A eficácia da resposta final do LLM é limitada superiormente pela qualidade desses documentos recuperados, refletindo o princípio *Entra Lixo, Sai Lixo* (*Garbage In, Garbage Out*) [Zhao et al., 2025]. Para maximizar essa qualidade, este trabalho avalia e combina dois paradigmas distintos de recuperação: a busca vetorial densa e a busca lexical esparsa.

2.4.1 Recuperação Vetorial (Busca Densa)

Conforme estabelecido na Seção 2.1, a representação vetorial mapeia o texto para um espaço contínuo onde a proximidade angular reflete a similaridade de significado. Na etapa de recuperação, a consulta original do usuário q é processada pelo mesmo modelo de *embedding* utilizado na indexação do corpus, sendo projetada como um vetor denso $\vec{q}$ no exato mesmo espaço latente dos documentos.

O processo de recuperação consiste fundamentalmente em um problema de ranqueamento (*ranking*). O algoritmo de busca compara o vetor da consulta $\vec{q}$ contra o vetor de cada documento ou *chunk* $\vec{d}_i \in D$ indexado no banco de dados. O grau de relevância de cada trecho de texto é quantificado calculando-se a Similaridade de Cosseno entre $\vec{q}$ e $\vec{d}_i$. Os documentos são então ordenados de forma decrescente com base nesse escore geométrico, e o sistema retorna o subconjunto dos *Top-k* resultados mais semanticamente próximos à consulta.

A grande vantagem desta abordagem é a sua capacidade inerente de capturar sinonímia e abstrações conceituais de forma contínua. O sistema consegue, por exemplo, atribuir um alto escore de ranqueamento a um documento que discorra sobre “sanção” a partir de uma consulta que utilize exclusivamente o termo “pena”, pois o treinamento do modelo garante que ambos os conceitos habitem a mesma vizinhança semântica.

Contudo, por condensar toda a semântica de um texto longo em uma representação densa de tamanho fixo, essa técnica frequentemente sofre com a diluição da importância de termos muito específicos. Como o vetor é uma composição contextual ponderada, o modelo tende a falhar na recuperação de correspondências exatas de palavras-chave raras, numerações de incisos ou identificadores únicos [Manning et al., 2008], exigindo a introdução de um mecanismo complementar de busca exata para mitigar essas perdas.

2.4.2 Recuperação Lexical Probabilística (Sparse Retrieval)

Para suprir a deficiência vetorial em capturar termos exatos cruciais no domínio jurídico, como o número de uma lei (“8.666”) ou o nome próprio de uma comarca, utiliza-se a recuperação lexical.

A base teórica deste método é a estatística de frequência. Uma abordagem ingênua contaria apenas a Frequência do Termo (*TF*). Contudo, palavras funcionais como “o”, “de” ou “para” são extremamente frequentes e carregam pouca informação discriminativa. Para corrigir isso, a Teoria da Informação introduz a *Inverse Document Frequency* (IDF), proposta por Sparck Jones [1972], que penaliza termos comuns e valoriza termos raros:

$$IDF(t) = \log \left(\frac{N - n(t) + 0.5}{n(t) + 0.5} \right), \quad (6)$$

onde N é o total de documentos no *corpus* e $n(t)$ é o número de documentos contendo o termo t .

O algoritmo adotado, o *Okapi BM25* [Robertson et al., 1995], é uma evolução robusta dessa lógica ao introduzir a saturação de frequência. Diferente da contagem simples onde a relevância cresce linearmente com a repetição da palavra, o BM25 aplica uma curva assintótica controlada pelo parâmetro k_1 . Além disso, normaliza o *score* pelo tamanho do documento ($|d|$) em relação à média do *corpus* (*avgdl*) via parâmetro b :

$$\text{Score}(d, q) = \sum_{t \in q} IDF(t) \cdot \frac{f(t, d) \cdot (k_1 + 1)}{f(t, d) + k_1 \cdot \left(1 - b + b \cdot \frac{|d|}{\text{avgdl}} \right)}. \quad (7)$$

Essa formulação probabilística justifica o uso do BM25 como o componente de precisão cirúrgica do sistema. O desafio arquitetural que emerge, portanto, é como integrar os resultados ortogonais desta busca lexical com os da busca vetorial.

2.4.3 Fusão Híbrida de Rankings

A combinação das buscas Vetorial e Lexical não é trivial, pois suas distribuições de pontuação são incompatíveis. O Cosseno varia no intervalo $[-1, 1]$, enquanto o BM25 produz pontuações no intervalo $[0, \infty)$. Para unificar essas abordagens sem depender de normalizações sensíveis a *outliers* e calibrações manuais de pesos, utiliza-se o algoritmo de Fusão de Rank Recíproco (RRF - *Reciprocal Rank Fusion*) proposto por Cormack et al. [2009]. Este método é não-paramétrico e ignora os valores absolutos dos *scores*, baseando-se estritamente na posição (posto) do documento em cada lista ordenada de resultados.

O *score* final de um documento é dado pela soma harmônica dos inversos dos seus *rankings*:

$$RRFscore(d) = \sum_{j \in \mathcal{S}} \frac{1}{\eta + r_j(d)}, \quad (8)$$

onde $\mathcal{S}$ é o conjunto de sistemas (Vetorial e Lexical), $r_j(d)$ é a posição ordinal do documento d no sistema j , e η é uma constante de suavização definida como 60 [Cormack et al., 2009]. Na prática, o RRF atua como um mecanismo de consenso: penaliza documentos que aparecem no topo de apenas uma lista isolada e favorece fortemente aqueles que são classificados como relevantes por ambos os métodos simultaneamente [Yu et al., 2024].

2.4.4 Tamanho do Contexto

Após o processamento dos algoritmos de busca e a fusão dos ranqueamentos, o sistema de recuperação produz uma lista ordenada contendo, potencialmente, milhares de fragmentos de texto. Devido às restrições arquiteturais da janela de contexto dos LLMs e aos altos custos computacionais de inferência, é inviável submeter todo esse acervo documental ao modelo gerador. Para contornar essa limitação técnica, aplica-se uma operação de truncamento na lista de resultados, selecionando apenas os k documentos com as maiores pontuações de relevância. Este limite de corte é governado pelo hiperparâmetro *Top-k*.

A definição deste valor envolve uma análise de custo-benefício informacional crítico na arquitetura RAG, impactando diretamente o balanço entre sinal e ruído:

- **Subdimensionamento (Baixo k):** Restringe severamente o contexto, minimizando a injeção de ruído no *prompt* do LLM. No entanto, eleva substancialmente o risco de exclusão de evidências cruciais (falsos negativos), reduzindo a revocação (*recall*) do sistema e privando o modelo da fundamentação necessária para gerar uma resposta correta.
- **Superdimensionamento (Alto k):** Maximiza a probabilidade de incluir o fragmento exato que resolve a consulta da busca. Em contrapartida, inunda o modelo com informações periféricas. Conforme evidenciado por Liu et al. [2024], a inserção de contextos excessivamente longos degrada a capacidade de atenção do LLM para informações localizadas no meio do texto, um viés arquitetural diagnosticado como o fenômeno *Lost in the Middle*.

Portanto, o hiperparâmetro *Top-k* atua como a válvula de controle informacional primária entre o módulo de recuperação e o módulo de geração. Sua calibração busca o ponto de equilíbrio exato onde o contexto fornecido é rico o suficiente para embasar a resposta, mas conciso o bastante para não corromper os mecanismos de atenção da rede neural subjacente.

2.5 Avaliação Automatizada e Métricas

Para superar as limitações das métricas tradicionais baseadas em sobreposição de caracteres (n-gramas), como BLEU [Papineni et al., 2002] e ROUGE [Lin, 2004], este trabalho adota o paradigma *LLM-as-a-Judge* [Zheng et al., 2023] utilizando o *framework* de Avaliação de Geração Aumentada por Recuperação (Retrieval Augmented Generation Assessment - Ragas) [Es et al., 2023a]. A avaliação combina métricas sem referência (*reference-free*), fundamentadas teoricamente por Es et al. [2023b], e métricas baseadas em referência (*ground truth*), implementadas conforme a documentação técnica da biblioteca [Gradients, 2024].

O processo avaliativo é dividido estruturalmente: inicia-se com a criação da base de validação e desdobra-se em cinco métricas principais, sendo duas focadas na etapa de recuperação, duas na etapa de geração e uma métrica de qualidade global da resposta.

2.5.1 Geração Sintética do Conjunto de Teste

A avaliação rigorosa e o posterior DoE de um sistema RAG exigem um conjunto de teste robusto. Este conjunto deve ser composto por triplas contendo: a consulta do usuário (q), o contexto de referência documentado (c) e a resposta ideal esperada (a), comumente referida como gabrito ou *Ground Truth*.

Em domínios especializados e extensos como o jurídico, a anotação manual dessas triplas por especialistas do domínio é financeiramente e temporalmente proibitiva. Para contornar esse gargalo metodológico, a literatura contemporânea legitima a Geração Sintética de Dados orientada por LLM.

Nesta abordagem, utiliza-se um LLM de fronteira (estado da arte) com a diretriz estrita de atuar como um gerador de dados. O algoritmo fornece fragmentos do *corpus* normativo ao modelo e o instrui a formular perguntas realistas baseadas exclusivamente naquele trecho, extraindo a resposta correspondente. Este procedimento garante a criação de um gabarito escalável, com diversidade linguística controlada e 100% lastreado no acervo oficial. Uma vez estabelecido este padrão ouro sintético, torna-se possível aplicar as métricas de avaliação automatizada.

2.5.2 Precisão do Contexto (*Context Precision*)

Com o gabarito sintético estabelecido, o primeiro passo da avaliação concentra-se na qualidade do ordenamento (*ranking*) realizado pelo módulo de recuperação. Diferente de métricas estáticas que apenas verificam a presença da informação na lista final, a *Context Precision* mensura se os documentos mais relevantes foram priorizados no topo. Isso é crítico para o desempenho de LLMs devido ao viés de primazia [Liu et al., 2023].

Conforme a definição formal do *Ragas*, o *score* é calculado através da média da precisão em k ponderada pela relevância posicional:

$$Precision@K = \frac{\sum_{k=1}^K (P_k \cdot v_k)}{\sum_{k=1}^K v_k}, \quad (9)$$

onde:

- P_k : é a precisão calculada até a posição k ;
- v_k : é o indicador binário de relevância na posição k (1 se relevante, 0 caso contrário);
- $\sum v_k$: representa o número total de documentos relevantes identificados dentro da janela K .

Valores próximos de 1 indicam que a informação útil foi apresentada nas primeiras posições, minimizando a injeção de ruído logo no início do *prompt*.

2.5.3 Revocação do Contexto (*Context Recall*)

Enquanto a Precisão foca na ordenação, é imperativo garantir que nenhuma informação vital foi deixada para trás. A métrica de *Context Recall* avalia a extensão em que o contexto recuperado (C) alinha-se com o gabarito sintético (G).

O algoritmo de cálculo utiliza o LLM atuando como juiz (*LLM-as-a-Judge*) para realizar uma auditoria sentença a sentença:

1. **Decomposição:** O gabarito oficial (G) é fragmentado em uma lista de sentenças ou afirmações atômicas individuais.
2. **Verificação de Atribuição:** Para cada sentença s_i do gabarito, o modelo verifica se ela pode ser atribuída ou deduzida a partir do contexto recuperado (C).

O *score* final é a razão entre as sentenças do gabarito que são suportadas pelo contexto e o total de sentenças do gabarito:

$$Recall = \frac{|\{s \in G \mid C \text{ suporta } s\}|}{|G|}. \quad (10)$$

Valores baixos nesta métrica indicam que o sistema de recuperação falhou em trazer o quadro completo, obrigando o modelo gerador a preencher as lacunas com seu conhecimento paramétrico interno, o que eleva o risco de alucinação.

2.5.4 Fidelidade (*Faithfulness*)

Uma vez validada a etapa de recuperação, a avaliação volta-se para o texto final produzido pelo LLM. O risco primário a ser mitigado na geração jurídica é a invenção de fatos. A métrica de *Faithfulness* mensura a consistência estrita da resposta gerada em relação ao contexto recuperado.

O cálculo é realizado em duas etapas sequenciais:

1. **Geração de Afirmações:** A resposta gerada (A) é decomposta em um conjunto de afirmações atômicas ($S = \{s_1, s_2, \dots, s_n\}$).
2. **Verificação de Suporte:** O juiz automatizado verifica, para cada s_i , se a afirmação pode ser inferida lógica e exclusivamente a partir do contexto (C).

O *score* é a razão entre o número de afirmações suportadas ($|V|$) e o total de afirmações extraídas ($|S|$):

$$Faithfulness = \frac{|V|}{|S|}. \quad (11)$$

2.5.5 Relevância da Resposta (*Answer Relevancy*)

Embora a Fidelidade garanta que o modelo não inventou fatos, ela não garante a utilidade da interação. Uma resposta pode ser fiel ao texto base, mas completamente evasiva em relação ao que o usuário perguntou. A métrica de *Answer Relevancy* resolve isso ao avaliar a pertinência direta da resposta.

Sendo uma métrica *reference-free*, ela opera sob a premissa geométrica de que, se uma resposta for perfeitamente relevante, deve ser possível aplicar engenharia reversa para adivinhar a pergunta original. O cálculo segue três etapas:

1. **Geração de Perguntas Artificiais:** Um LLM analisa a resposta gerada e cria um conjunto de $N = 3$ (padrão do Rags) perguntas prováveis (Q_{g_i}) que poderiam ter motivado aquele texto.
2. **Embeddings:** Converte-se a pergunta original do usuário (Q_o) e as artificiais (Q_{g_i}) em vetores no espaço latente.
3. **Cálculo de Similaridade:** Calcula-se a similaridade de cosseno entre o vetor da pergunta original (E_o) e os vetores gerados (E_{g_i}).

A pontuação final é a média aritmética dessas similaridades:

$$Relevancy = \frac{1}{N} \sum_{i=1}^N \cos(E_{g_i}, E_o). \quad (12)$$

Valores próximos a zero penalizam severamente o sistema por saídas genéricas, tangenciais ou redundantes.

2.5.6 Corretude da Resposta (*Answer Correctness*)

Por fim, para consolidar a avaliação de toda a arquitetura, a métrica global de *Answer Correctness* compara o produto final (A) diretamente com o gabarito sintético (G).

O *framework* emprega uma abordagem híbrida, combinando semântica e factualidade:

1. **Corretude Factual:** O LLM decompõe a resposta e o gabarito em afirmações, classificando-as em Verdadeiros Positivos (TP - presentes em ambos), Falsos Positivos (FP - alucinações da resposta) e Falsos Negativos (FN - omissões da resposta). O *score* deriva de um *F1-Score* modificado:

$$Score_{factual} = \frac{TP}{TP + 0.5 \times (FP + FN)} \quad (13)$$

2. **Similaridade Semântica:** Calcula-se a similaridade de cosseno entre os vetores da resposta gerada e do gabarito ($Score_{semantic}$), servindo como um fator de amortecimento que reconhece o significado global mesmo havendo variações de vocabulário.

O *score* final de corretude é a média ponderada desses dois componentes. Tipicamente, o *framework* atribui maior peso (0.75) à precisão factual em detrimento da similaridade vetorial (0.25), resultando na equação:

$$Answer_Correctness = 0.75 \times Score_{factual} + 0.25 \times Score_{semantic} \quad (14)$$

2.6 Planejamento de Experimentos

A otimização de arquiteturas complexas como o RAG exige a transição de abordagens de tentativa e erro para uma investigação sistemática. O DoE fornece o arcabouço estatístico necessário para modelar e analisar simultaneamente múltiplas variáveis de entrada (fatores) e quantificar seus impactos nas variáveis de saída (respostas) [Montgomery, 2017].

2.6.1 Modelo Fatorial Completo

Para avaliar não apenas o efeito isolado de cada hiperparâmetro, mas também as sinergias e dependências entre eles, emprega-se o delineamento Fatorial Completo. Neste arranjo, os tratamentos consistem em todas as combinações possíveis dos níveis de todos os fatores em estudo.

O modelo estatístico linear generalizado para um arranjo fatorial com k fatores e n réplicas pode ser expresso como:

$$Y_{i_1 i_2 \dots i_k r} = \mu + \sum_{j=1}^k \tau_{j, i_j} + \sum_{j < m} (\tau\tau)_{jm, i_j i_m} + \dots + (\tau_{1\dots k})_{i_1 \dots i_k} + \epsilon_{i_1 i_2 \dots i_k r} \quad (15)$$

onde:

- $Y_{i_1 i_2 \dots i_k r}$ é a resposta observada na r -ésima réplica da combinação específica de níveis ($i_1, i_2, \dots, i_k$) dos k fatores;
- μ é a média global teórica do experimento;
- $\sum_{j=1}^k \tau_{j, i_j}$ representa a soma dos efeitos principais de cada um dos k fatores isoladamente;

- $\sum_{j < m} (\tau\tau)_{jm, i_j i_m}$ e os termos subsequentes englobam todos os efeitos de interação entre os fatores (de segunda ordem, terceira ordem, e assim sucessivamente, até a interação global de ordem k);
- $\epsilon_{i_1 i_2 \dots i_{k_r}}$ é o componente de erro aleatório experimental.

O teste de hipóteses clássico para avaliar a significância simultânea destes efeitos é a Análise de Variância (*Analysis Of Variance* - ANOVA). Contudo, a validade de suas inferências (o valor-p derivado da distribuição F) depende estritamente do comportamento probabilístico do termo de erro.

2.6.2 Pressupostos da ANOVA e Limitações em Métricas de RAG

A validade estatística das inferências derivadas da ANOVA fundamenta-se na estrutura do termo de erro. A formulação exige que os resíduos do modelo ($\epsilon_{i_1 \dots i_{k_r}}$) sejam independentes, identicamente distribuídos e sigam uma distribuição Normal com média zero e variância constante (σ^2), condição conhecida como homocedasticidade: $\epsilon \sim N(0, \sigma^2)$.

Em avaliações de sistemas de recuperação de informação, as variáveis de resposta (como Precisão, Revocação e as métricas do *Ragas*) apresentam desafios intrínsecos a esses pressupostos:

- **Limites de Intervalo:** Por serem proporções ou índices limitados ao intervalo $[0, 1]$, a variância tende a ser menor nas extremidades do que no centro do intervalo, violando a homogeneidade de variâncias.
- **Assimetria e Bimodalidade:** As distribuições em RAG são frequentemente enviesadas, com concentrações de *scores* próximos a 1 (em sistemas otimizados) ou 0 (em falhas de recuperação).

Tais características invalidam o uso da ANOVA paramétrica padrão, elevando o risco de Erro Tipo I e de conclusões espúrias sobre a superioridade de uma configuração de modelo.

2.6.3 Modelagem Não-Paramétrica: O Método ART

Para viabilizar a análise fatorial em dados que violam os pressupostos clássicos, Wobbrock et al. [2011b] propuseram o procedimento *Aligned Rank Transform* (ART). Este método permite manter a capacidade analítica de decomposição de efeitos principais e, crucialmente, de interações, superando a limitação de testes não-paramétricos tradicionais como o de Kruskal-Wallis, que se restringem a análises unifatoriais.

A transformação matemática do ART ocorre em três etapas fundamentais, executadas de forma independente para cada efeito (principal ou interação) que se deseja testar:

1. **Alinhamento:** Para isolar o efeito de um fator específico (ex: fator A), o método remove da resposta bruta Y os efeitos estimados de todos os outros fatores e interações presentes no modelo (*nuisance effects*). Para o fator A , o valor alinhado Y_{align} é calculado como:

$$Y_{align(A)} = Y - \left[\hat{\mu} + \hat{\beta} + (\widehat{\tau\beta}) + \dots \right] \quad (16)$$

onde os termos entre colchetes representam as estimativas de todos os efeitos, exceto o de A .

2. **Atribuição de Postos (*Ranking*):** Os valores alinhados são convertidos em seus respectivos postos (posições em uma ordem crescente). Esta etapa é a que confere robustez ao método, pois a análise baseada em postos neutraliza a influência de *outliers* e contorna a necessidade de normalidade da distribuição original, tornando-o ideal para métricas de RAG com distribuições assimétricas.
3. **Aplicação da ANOVA:** Aplica-se a ANOVA convencional sobre os postos alinhados. Como o processo de alinhamento garantiu que a variação remanescente nos dados (além do erro) se refere especificamente ao fator testado, a estatística F resultante é válida para testar a significância do efeito, permitindo inclusive testes de comparações múltiplas (*post-hoc*) não-paramétricos [Elkin et al., 2021].

2.6.4 Contrastes e Controle de Erro (Pós-Hoc)

Uma vez que a ANOVA (seja clássica ou via ART) detecta significância estatística em um fator com mais de dois níveis ou em uma interação, faz-se necessário o uso de testes de múltiplos contrastes (*post-hoc*) para identificar exatamente entre quais grupos reside a diferença. No caso do ART, estas comparações são realizadas utilizando as diferenças entre os Postos Médios Alinhados ($\bar{R}$) dos grupos testados [Elkin et al., 2021].

Entretanto, a realização de múltiplos testes de hipóteses sobre o mesmo conjunto de dados inflaciona o erro do Tipo I (a probabilidade de rejeitar falsamente a hipótese nula). Se α é o nível de significância de um teste individual, a probabilidade de cometer pelo menos um erro Tipo I em m comparações independentes cresce conforme $1 - (1 - \alpha)^m$.

Para restaurar o rigor estatístico global do experimento, a literatura exige a aplicação de mecanismos de penalização de *p-valor*. A estratégia mais conservadora e amplamente adotada é a Correção de Bonferroni [Dunn, 1961], que ajusta a probabilidade final multiplicando o *p-valor* bruto pelo número de comparações realizadas ($p_{ajustado} = p \times m$), exigindo uma diferença substancialmente maior entre os postos para que a significância seja declarada.

3 Trabalhos Relacionados

A rápida evolução da arquitetura RAG estimulou uma vasta produção acadêmica focada na engenharia de seus componentes e na aplicação em domínios de alta precisão. A literatura recente evidencia uma lacuna entre estudos empíricos de melhores práticas e a validação estatística rigorosa dessas configurações em línguas e domínios específicos.

No contexto global de otimização, Wang et al. [2024] conduziram uma investigação extensiva sobre a sensibilidade dos sistemas RAG a escolhas de *design* e analisaram empiricamente o impacto de estratégias de segmentação e recuperação. Embora estabeleçam diretrizes valiosas para domínios gerais, a análise baseia-se majoritariamente em estudos de ablação, ou remoção de componentes, e observação direta de métricas, sem a aplicação de um formalismo como o DoE para quantificar interações complexas entre fatores. Nosso trabalho preenche essa lacuna metodológica ao aplicar o método ART para validar estatisticamente essas práticas.

A granularidade da informação recuperada é outro ponto crítico. Zhang et al. [2024b] demonstraram que a estratégia de *chunking* afeta drasticamente a coerência semântica e sugerem que quebras baseadas em significado superam cortes recursivos simples. Estendemos essa investigação ao testar essa hipótese em textos jurídicos brasileiros, caracterizados por sentenças longas e vocabulário arcaico, um cenário onde a preservação do contexto é ainda mais desafiadora do que nos *corpora* de língua inglesa tipicamente avaliados.

Quanto à aplicação em domínios sensíveis, Johnson et al. [2023] consolidaram o uso de RAG na área da saúde e evidenciaram sua capacidade de reduzir alucinações em contextos críticos. No cenário nacional, de Aquino et al. [2024] iniciaram a exploração de RAG em documentos jurídicos brasileiros com foco na arquitetura de extração de informações. Contudo, este estudo anterior priorizou a viabilidade técnica e a validação qualitativa. A presente pesquisa avança ao focar na otimização quantitativa dos parâmetros de recuperação e utiliza o paradigma *LLM-as-a-Judge* para auditar a fidelidade do sistema frente a um acervo legislativo não estruturado.

Por fim, no que tange às técnicas de refinamento de busca, propostas recentes como o RankRAG [Yu et al., 2024] utilizam modelos neurais avançados, os *Cross-Encoders*, para reordenar documentos. Embora eficazes, esses modelos introduzem latência significativa na inferência. Em contraste, nossa pesquisa investiga a eficácia do algoritmo RRF como uma alternativa computacionalmente eficiente para fundir buscas vetoriais e lexicais, buscando um equilíbrio entre precisão e custo computacional viável para instituições públicas.

Predominam na literatura abordagens empíricas carentes de rigor estatístico. Especificamente no domínio jurídico nacional, os trabalhos priorizam a implementação arquitetural em detrimento da otimização paramétrica, conforme sintetizado na Tabela 1.

Tabela 1: Síntese das lacunas e contribuições da pesquisa.

Estudo	Lacuna / Abordagem	Solução Proposta
Wang et al. [2024]	Empirismo e ablação sem validação formal.	Uso de DoE e ART para inferência.
de Aquino et al. [2024]	Foco arquitetural e validação qualitativa.	Otimização quantitativa via <i>Ragas</i> .
Zhang et al. [2024b]	Testes focados na língua inglesa.	<i>Chunking</i> semântico para Jurídico PT-BR .
Yu et al. [2024]	Re-ranking neural de alta latência.	Uso de RRF (alternativa estatística).

4 Metodologia

Este capítulo detalha os procedimentos computacionais e o planejamento estatístico adotados para a construção, otimização e avaliação automatizada do sistema RAG aplicado ao acervo normativo do MPES. A pesquisa caracteriza-se como um estudo experimental empírico e quantitativo, estruturado rigorosamente para mensurar o impacto isolado e as interações sinérgicas de diferentes hiperparâmetros arquiteturais na qualidade da informação recuperada e gerada.

Para garantir a reprodutibilidade e a validade interna, a exposição metodológica segue uma ordem lógico-construtiva: inicia-se com a formalização do Delineamento Experimental e a definição das variáveis. Em seguida, detalha-se a engenharia de dados e o processo de curadoria sintética do conjunto de teste. Por fim, descrevem-

se os protocolos estritos de execução em lote das inferências e a modelagem estatística não-paramétrica ART empregada para testar as hipóteses do estudo.

4.1 Delineamento Experimental

Para investigar sistematicamente o espaço de hiperparâmetros do sistema, adotou-se um Delineamento Fatorial Completo cruzado. Esta abordagem permite avaliar não apenas os efeitos principais de cada componente do RAG, mas também as interações de ordem superior entre eles. O experimento foi estruturado a partir de quatro fatores independentes, cujos níveis estão sumarizados na Tabela 2.

Tabela 2: Fatores e níveis do delineamento fatorial completo.

Fator	Níveis	Total de Níveis
Segmentação (<i>Chunking</i>)	Recurso Fino (500 carac., 100 <i>overlap</i>)	4
	Recurso Médio (1000 carac., 200 <i>overlap</i>)	
	Semântico Percentil 75 (P_{75})	
	Semântico Percentil 95 (P_{95})	
Algoritmo de Busca (<i>Retrieval</i>)	Vetorial (Densa via Cosseno)	3
	Lexical (Esparsa via BM25)	
	Híbrida (Fusão via RRF)	
Volume de Contexto (Top- k)	$k = 5$	4
	$k = 10$	
	$k = 15$	
	$k = 20$	
Modelo Gerador (LLM)	gpt-4o	2
	gpt-4o-mini	

O arranjo fatorial completo, caracterizado pelo cruzamento de todos os níveis descritos, resulta em um espaço experimental de $4 \times 3 \times 4 \times 2 = 96$ configurações únicas de sistema (tratamentos).

4.1.1 Unidade Experimental e Variáveis de Resposta

A unidade experimental base para este estudo é a consulta individual. O experimento utilizou um *Golden Set* composto por $N = 40$ perguntas inéditas, atuando como réplicas verdadeiras para cada tratamento. Consequentemente, o delineamento produziu um total de $96 \times 40 = 3.840$ observações independentes. As variáveis de resposta coletadas para cada observação correspondem às cinco métricas de qualidade automatizadas calculadas pelo *framework Ragas*: *Context Precision*, *Context Recall*, *Faithfulness*, *Answer Relevancy* e *Answer Correctness*.

4.2 Infraestrutura e Preparação da Base Documental

A implementação computacional foi orquestrada em Python 3.11 utilizando o *framework LangChain* [Chase, 2023]. A estrutura operacional do sistema conta com uma interface de interação direta desenvolvida em *Gradio* (Apêndice C) e um orquestrador construído em *FastAPI*, cuja documentação interativa e parametrização estão detalhadas no Apêndice D. O fluxo completo de engenharia de dados, desde a captura da legislação bruta até sua disponibilização no índice vetorial, é detalhado na Figura 6. Este fluxo de Extração, Transformação e Carga (*Extract, Transform, Load* - ETL) compreende a coleta automatizada no portal do MPES, a higienização dos textos, o processamento em paralelo das quatro estratégias de segmentação e, por fim, a persistência dos vetores no banco de dados *ChromaDB*.

4.2.1 Extração de Dados e Sincronização

A base documental primária foi extraída do portal “Legislação Compilada” Ministério Público do Estado do Espírito Santo [2024] do MPES (conforme ilustrado no Apêndice B). O *pipeline* operou via *web scraping* automatizado com a biblioteca *Requests* [Reitz, 2023], tendo a coleta finalizada em 10 de Julho de 2025, processando todos os 2360 documentos disponíveis até a data.

O algoritmo manipulou *tokens* de sessão para paginação programática e implementou uma rotina de sincronização incremental. Essa rotina assegura a consistência temporal ao baixar apenas normas inéditas e realizar a remoção de documentos revogados. Após a extração, a biblioteca *BeautifulSoup* foi utilizada para a higienização do conteúdo bruto, resultando em um *corpus* em formato de texto plano.




Figura 6: Fluxograma do processo de ETL e preparação da base documental.

4.2.2 Implementação das Estratégias de Segmentação

Em conformidade com o delineamento experimental, o *corpus* foi submetido a quatro estratégias paralelas de particionamento. Para a abordagem recursiva, utilizou-se o `RecursiveCharacterTextSplitter` para gerar blocos fixos de 500 e 1000 caracteres, com sobreposições (*overlaps*) de 100 e 200 caracteres, respectivamente.

Já a segmentação semântica foi executada via `SemanticChunker`, que identifica pontos de corte dinâmicos baseados nos percentis P_{75} e P_{95} da distribuição de dissimilaridade de cosseno entre sentenças adjacentes, com limite de 8192 *tokens*, o máximo suportado pelo modelo de *embedding* utilizado. Em ambas as abordagens, a biblioteca `tiktoken` foi integrada como mecanismo de controle para garantir a aderência aos limites de *tokens* da API.

4.2.3 Vetorização e Indexação

Os fragmentos foram projetados no espaço vetorial denso através do modelo `text-embedding-3-small` [OpenAI, 2024]. A persistência e gestão do acervo vetorizado ocorreram no *ChromaDB* [Team, 2023]. A escolha deste banco de dados vetorial justifica-se por sua arquitetura otimizada para cálculos de similaridade, essencial para suportar a volumetria e a latência exigidas pelos 96 tratamentos do experimento.

4.3 Geração do Conjunto de Avaliação Sintética

Para viabilizar a análise quantitativa, construiu-se um *Golden Set* padronizado utilizando a metodologia de Geração Sintética assistida por LLM (*LLM-as-a-Generator*). O processo consistiu na amostragem aleatória de $N = 100$ documentos do *corpus* higienizado para servirem de âncora factual.

Este texto base foi submetido ao modelo GPT-4o, instruído via *System Prompt* (Apêndice A) a atuar como um especialista jurídico. O fluxo de geração foi condicionado para garantir uma distribuição equitativa das perguntas entre quatro categorias taxonômicas de complexidade, cada uma desenhada para testar diferentes competências do fluxo de processamento (*pipeline*):

- **Factual (Baixa Complexidade):** Questões de consulta direta que exigem a recuperação de um dado explícito no texto, como nomes de órgãos, datas ou prazos específicos. Testam a capacidade básica de busca léxica e densa.
- **Procedimental (Média Complexidade):** Perguntas focadas no "como", exigindo que o modelo identifique e ordene etapas de um processo administrativo ou jurídico descrito na norma. Exigem que o *chunking* tenha preservado a continuidade lógica das instruções.

- **Síntese e Integração (Alta Complexidade):** Demandam que o modelo correlacione múltiplos parágrafos ou seções de um documento para formular uma resposta abrangente. Esta categoria testa a janela de contexto e a capacidade do LLM de resumir informações dispersas sem alucinar.
- **Recuperação Fina (*Agulha no Palheiro*):** Questões formuladas sobre detalhes minuciosos e isolados inseridos em documentos extensos. O objetivo é avaliar a sensibilidade do algoritmo de busca em identificar o sinal correto em meio a um volume elevado de ruído contextual (Top- k alto).

O resultado final consolidou um conjunto de 40 triplas de avaliação, compostas por Pergunta, Resposta Ideal (Gabarito) e Citação de Evidência (Trecho exato da norma). Este conjunto provê a base de comparação necessária para o cálculo das métricas de desempenho e para a posterior análise estatística via método ART.

4.4 Procedimentos de Execução e Coleta de Dados

Para assegurar a validade interna e o isolamento dos fatores, o experimento foi executado em um fluxo estritamente controlado. O pipeline de execução, detalhado na Figura 7, ilustra o percurso sistemático de cada consulta do *Golden Set* através dos módulos de recuperação híbrida, fusão de *rankings* e inferência final.




Figura 7: Pipeline de execução experimental do sistema RAG.

4.4.1 Controle de Variáveis

A fim de neutralizar variáveis de confusão, a temperatura dos modelos geradores foi fixada em $T = 0.1$ e utilizou-se um único *System Prompt* padronizado (Apêndice B) com restrições negativas contra alucinações.

4.4.2 Fluxo de Inferência

Conforme o esquema detalhado na Figura 7, a execução experimental ocorreu em duas fases sequenciais e interdependentes:

Fase 1: Recuperação (*Retrieval*) Esta fase inicia-se no Banco de Perguntas, onde cada consulta é direcionada ao módulo de Busca. O sistema opera em três frentes paralelas: a similaridade de cosseno sobre o *ChromaDB* (Busca Vetorial), o algoritmo BM25 (Busca Lexical) ou a integração de ambos via *Reciprocal Rank Fusion* (RRF). O resultado desta etapa é a consolidação de um Banco de Contexto contendo os documentos recuperados com maior relevância estatística.

Fase 2: Geração (*Generation*) O módulo de geração consome os dados do Banco de Contexto sob um critério de seleção determinística (*Top-k*), simulando janelas de contexto com $\{5, 10, 15, 20\}$ fragmentos. Os textos selecionados são injetados nos modelos `gpt-4o` ou `gpt-4o-mini`, conforme o tratamento experimental. A resposta gerada é então persistida em um Banco de Respostas tabular (CSV) para análise posterior.

4.4.3 Protocolo de Avaliação (*LLM-as-a-Judge*)

Com o *dataset* de inferências concluído, procedeu-se à mensuração utilizando o *framework Ragas*. Instanciou-se um juiz sintético (`gpt-4o`, $T = 0$) para garantir determinismo absoluto na avaliação.

O avaliador consumiu exclusivamente o contexto efetivamente injetado no *prompt* após a etapa de fatiamento do *Top-k*, assegurando que as métricas de fidelidade e precisão refletissem com exatidão a relação entre o insumo recuperado e o produto final gerado para cada uma das 3.840 unidades experimentais.

4.5 Análise Estatística dos Dados

O conjunto de dados consolidado, composto pelos *scores* das métricas para as 3.840 unidades experimentais, foi exportado para o ambiente estatístico R versão 4.3. Dada a natureza das métricas de RAG — limitadas ao intervalo $[0, 1]$ e com distribuições inerentemente assimétricas — a análise fundamentou-se no método *Aligned Rank Transform* (ART).

4.5.1 Análise Descritiva e Exploratória

Previamente à modelagem inferencial, realizou-se uma análise estatística descritiva para caracterizar o comportamento das métricas em cada nível dos fatores. Esta etapa incluiu o cálculo de medidas de tendência central (média e mediana) e de dispersão (desvio padrão e erro padrão), além da construção de diagramas de caixa (*boxplots*). Essa exploração visual é indispensável para identificar padrões preliminares, detectar *outliers* e compreender a variabilidade dos *scores* antes da transformação por postos.

4.5.2 Especificação do Modelo Aditivo Aplicado

A investigação das fontes de variação sobre o desempenho do sistema foi conduzida através de um modelo de efeitos principais fixos, assumindo a aditividade dos fatores. Utilizando o pacote `ARTool`, ajustou-se o seguinte modelo linear para cada métrica de resposta (Y):

$$Y_{ijklr} = \mu + S_i + B_j + K_k + M_l + \epsilon_{ijklr} \quad (17)$$

onde os termos representam os componentes do experimento:

- Y_{ijklr} é o escore da métrica observado na r -ésima repetição;
- μ é a média global do experimento;
- S_i representa o efeito principal da Estratégia de Segmentação ($i = 1, \dots, 4$);
- B_j representa o efeito principal do Algoritmo de Busca ($j = 1, \dots, 3$);
- K_k representa o efeito principal do Volume de Contexto *Top-k* ($k = 1, \dots, 4$);
- M_l representa o efeito principal do Modelo Gerador LLM ($l = 1, 2$);
- ϵ_{ijklr} é o erro aleatório experimental.

A validação de hipóteses seguiu um fluxo hierárquico: avaliou-se a significância dos efeitos via tabela ANOVA do ART, seguida de contrastes *post-hoc* para os fatores significativos. Aplicou-se a correção de Bonferroni ($p_{ajustado}$) para controlar a taxa de erro familiar decorrente das múltiplas comparações, garantindo a robustez das inferências sobre qual configuração de sistema RAG é estatisticamente superior.

5 Resultados e Discussão

Este capítulo apresenta a análise detalhada do desempenho do sistema de RAG, baseada em um esforço experimental de $N = 3.840$ observações. A avaliação objetiva mensurar o impacto individual e combinado dos quatro hiperparâmetros controlados: Estratégia de Segmentação, Tipo de Busca, Janela de Contexto (k) e Modelo LLM, sobre a qualidade final das respostas jurídicas.

5.1 Análise Descritiva e dos Fatores Experimentais

A inspeção inicial dos dados revela padrões distribucionais que justificam a adoção de métodos não-paramétricos robustos. A Figura 8 apresenta os histogramas de frequência para as cinco métricas de avaliação.




Figura 8: Distribuição de Frequência das Métricas de Avaliação.

Fonte: Elaborado pelo autor.

A análise visual permite três diagnósticos fundamentais: (i) as métricas de recuperação exibem um comportamento polarizado (“tudo ou nada”), com concentração massiva em 1,0; (ii) a *Faithfulness* demonstra que os modelos testados raramente alucinam, mantendo alta aderência factual; e (iii) a *Answer Correctness* apresenta multimodalidade, refletindo sua natureza híbrida que penaliza erros factuais mesmo em respostas coerentes.

A seguir, detalha-se o impacto isolado de cada hiperparâmetro, com as médias organizadas pelas etapas do *pipeline* RAG: Recuperação, Geração e Avaliação Global.

5.1.1 Estratégia de Segmentação (*Chunking*)

A Tabela 3 apresenta os resultados por estratégia de particionamento. Observa-se que a fragmentação excessiva (*Recursive 500*) gera o pior desempenho em todas as dimensões. Em contrapartida, a abordagem *Semantic (P95)* obteve o maior *Recall* médio (0,89), sugerindo que janelas baseadas em mudanças de tópico preservam melhor a completude da informação jurídica.

Tabela 3: Desempenho médio por Estratégia de *Chunking*.

Estratégia	Recuperação		Geração		Global
	Recall	Precision	Faithful.	Relevancy	Correct.
Recursive (1000)	0,81	0,94	0,95	0,78	0,61
Recursive (500)	0,65	0,86	0,89	0,71	0,52
Semantic (P75)	0,81	0,87	0,88	0,74	0,59
Semantic (P95)	0,89	0,93	0,91	0,77	0,62

5.1.2 Estratégia de Busca

A Tabela 4 apresenta o desempenho comparativo entre os algoritmos de busca. A **Busca Híbrida** superou as abordagens isoladas em todas as categorias, demonstrando que a combinação da precisão terminológica do BM25 com a abrangência semântica dos vetores resulta em um sistema mais robusto para o domínio jurídico.

5.1.3 Janela de Contexto (Top-K)

O impacto do volume de contexto recuperado é detalhado na Tabela 5. Observa-se um crescimento consistente e linear dos escores conforme a janela se expande. O limite de **Top-20** apresentou os melhores resultados,

Tabela 4: Desempenho médio por Tipo de Busca.

Algoritmo	Recuperação		Geração		Global
	Recall	Precision	Faithful.	Relevancy	Correct.
Híbrida	0,83	0,93	0,93	0,78	0,62
Textual	0,74	0,86	0,89	0,73	0,55
Vetorial	0,80	0,92	0,91	0,75	0,60

indicando que, para o conjunto de dados do MPES, o benefício da informação adicional supera o risco de introdução de ruído no *prompt*.

Tabela 5: Desempenho médio por Tamanho da Janela (Top-K).

Nível	Recuperação		Geração		Global
	Recall	Precision	Faithful.	Relevancy	Correct.
Top-5	0,70	0,83	0,88	0,71	0,54
Top-10	0,79	0,91	0,92	0,76	0,59
Top-15	0,82	0,93	0,91	0,77	0,60
Top-20	0,85	0,94	0,92	0,78	0,62

5.1.4 Modelo LLM

A Tabela 6 valida a eficiência do modelo **GPT-4o-mini**, que apresentou desempenho superior em métricas de geração e corretude global, consolidando-se como a melhor opção de custo-benefício para o domínio jurídico do MPES.

Tabela 6: Desempenho médio por Modelo LLM.

Modelo	Recuperação		Geração		Global
	Recall	Precision	Faithful.	Relevancy	Correct.
GPT-4o	0,79	0,90	0,90	0,73	0,58
GPT-4o-mini	0,79	0,90	0,92	0,78	0,60

5.2 Análise Inferencial e Teste de Hipóteses

Para validar estatisticamente as diferenças observadas, aplicou-se o teste ART, ajustando-se modelos para mensurar o impacto dos efeitos principais sobre as métricas de qualidade. A Tabela 7 apresenta o sumário dos resultados transpostos, facilitando a visualização da influência de cada fator experimental através das diferentes métricas.

Tabela 7: Sumário da ANOVA (ART): Efeitos dos Fatores por Métrica.

Fator	Recall	Precision	Faithful.	Relevancy	Correct.
Chunking	92,44***	72,32***	9,22***	2,23 ^{ns}	35,06***
Busca	20,88***	61,48***	12,51***	3,87*	18,97***
Top-K	33,81***	47,21***	7,75***	3,68*	15,98***
Modelo	0,19 ^{ns}	38,44***	0,17 ^{ns}	18,62***	5,45*

Legenda: Valores F . *** $p < ,001$; * $p < ,05$; ^{ns} não sig.

A análise revela que o fator **Chunking** exerce a maior influência sobre as métricas de recuperação e a corretude global, enquanto o **Modelo** impacta predominantemente a precisão e a relevância das respostas geradas. Esse comportamento confirma que o ajuste fino dos hiperparâmetros de infraestrutura (segmentação e busca) é tão crítico quanto a escolha do modelo gerador para a eficácia do *pipeline*.

5.2.1 Decomposição dos Efeitos (*Post-hoc*)

Para identificar as diferenças pontuais entre os níveis dos fatores significativos na ANOVA, realizaram-se contrastes par-a-par com correção de Bonferroni. As tabelas a seguir apresentam a razão t (t -ratio) para as

comparações de interesse.

Tabela 8: Contrastes de *Chunking* (Referência: *Semantic P95*).

Contraste	Recall	Precision	Faithfulness	Correctness
Recursive 500 – P95	–16,59***	–7,10***	–9,41***	–9,54***
Recursive 1000 – P95	–7,40***	+3,36**	+0,02 ^{ns}	–1,80 ^{ns}
Semantic P75 – P95	–8,63***	–9,41***	–4,41***	–2,79*

Legenda: Razão t . *** $p < ,001$; ** $p < ,01$; * $p < ,05$; ^{ns} não sig.

O contraste da Tabela 8 utiliza a estratégia *Semantic P95* como referência por ter apresentado o maior *Recall* médio. Os resultados confirmam que a fragmentação excessiva (*Recursive 500*) degrada severamente todas as métricas. Nota-se um *trade-off* relevante: a estratégia *Recursive 1000* supera a referência em precisão ($t = 3,36$), mas falha em manter a mesma capacidade de recuperação ($t = -7,40$).

Tabela 9: Contrastes entre Algoritmos de Busca (Razão t).

Contraste	Recall	Precision	Faithfulness	Correctness
Híbrida – Textual	6,19***	10,08***	4,41***	6,05***
Híbrida – Vetorial	4,71***	1,05 ^{ns}	4,25***	2,06 ^{ns}
Vetorial – Textual	1,49 ^{ns}	9,05***	0,17 ^{ns}	4,01***

Legenda: *** $p < ,001$; * $p < ,05$; ^{ns} não sig.

Os contrastes da Tabela 9 evidenciam a superioridade da **Híbrida**. Ela se mostrou estatisticamente superior à busca puramente vetorial nas métricas de suporte (*Recall* e *Faithfulness*), embora a diferença na corretude final ($p > 0,05$) sugira que a fusão de *rankings* atua mais na robustez da evidência do que na qualidade gramatical da resposta.

Tabela 10: Contrastes de Volume de Contexto (Referência: $K = 20$).

Contraste	Recall	Precision	Correctness
$K = 5 - K = 20$	–9,81***	–11,80***	–6,56***
$K = 10 - K = 20$	–4,10***	–7,17***	–2,14 ^{ns}
$K = 15 - K = 20$	–3,01*	–6,91***	–1,50 ^{ns}

Legenda: Razão t . *** $p < ,001$; * $p < ,05$; ^{ns} não sig.

A análise da janela de contexto (Tabela 10) revela que o benefício de aumentar o K é mais acentuado na etapa de recuperação. O nível $K = 20$ superou estatisticamente o $K = 15$ em *Recall*, mas não gerou um incremento significativo na *Correctness*, indicando um platô de utilidade para o modelo gerador a partir de 15 fragmentos.

6 Conclusão

Este trabalho cumpriu seu objetivo geral ao desenvolver e validar uma metodologia experimental rigorosa para a otimização de sistemas RAG no domínio jurídico. Através de um experimento fatorial com $N = 3.840$ observações, superou-se a abordagem de tentativa e erro, substituindo-a por uma tomada de decisão baseada em evidências estatísticas. A aplicação da ART permitiu isolar os efeitos de cada hiperparâmetro, garantindo a validade das inferências mesmo diante da distribuição não-normal dos dados.

A seguir, detalha-se como cada objetivo específico foi alcançado à luz das novas evidências:

6.1 Cumprimento dos Objetivos Específicos

1. **Avaliar o impacto das estratégias de Chunking:** Demonstrou-se que a granularidade é o fator de maior impacto na arquitetura ($F = 35,06$ para Corretude). Os testes confirmaram a hipótese de que fragmentos pequenos (Recursiva 500) degradam severamente o desempenho ($p < 0,001$), rompendo a unidade semântica necessária para a recuperação legal. As estratégias Semântica (Percentil 95) e Recursiva (1000) mostraram-se estatisticamente equivalentes ($p > 0,05$), indicando que tanto a segmentação por tópicos quanto o uso de janelas amplas são soluções viáveis para mitigar a perda de contexto.

2. **Comparar a eficácia dos métodos de recuperação:** A análise consolidou a Busca Híbrida (RRF) como a abordagem mais segura para o domínio jurídico. Embora a métrica de Corretude final tenha apresentado empate técnico com a busca Vetorial ($p > 0.05$), a Híbrida mostrou-se estatisticamente superior na Revocação (*Recall*) e Fidelidade ($p < 0.001$). Conclui-se que o hibridismo atua como um mecanismo de "ancoragem", onde o componente léxico garante a recuperação de termos exatos da lei, prevenindo omissões críticas.
3. **Analisar o comportamento do sistema ao variar o Top-K:** Contrariando a expectativa inicial de que janelas muito grandes introduziriam ruído, os resultados mostraram que elevar K para 20 maximizou tanto a Revocação (0.85) quanto a Precisão (0.94). O aumento da precisão com janelas maiores sugere que, em janelas menores ($K = 5$ ou 10), o documento relevante sequer era recuperado; ao ampliar para $K = 20$, o documento é encontrado e corretamente posicionado no topo pelo *reranker* implícito da busca híbrida.
4. **Quantificar o ganho de desempenho entre modelos:** O experimento refutou a hipótese de que modelos massivos são indispensáveis para a tarefa. O modelo GPT-4o-mini apresentou desempenho estatisticamente superior ao modelo GPT-4o na métrica de Relevância ($t = 4.31, p < 0.001$) e marginalmente superior em Corretude. Observou-se que o modelo menor tende a ser mais conciso e aderente às instruções de formatação, enquanto o modelo maior ocasionalmente produz respostas prolixas, penalizando sua pontuação.

6.2 Recomendação Arquitetural para o MPES

Com base na síntese dos experimentos, recomenda-se a seguinte configuração de referência, que maximiza a qualidade técnica e a eficiência de custos para o assistente jurídico:

- **Ingestão:** Segmentação Semântica (Percentil 95) ou Recursiva (1000 tokens), priorizando blocos que preservem a integridade dos artigos de lei.
- **Busca:** Híbrida (Vetorial + BM25) com fusão por RRF, essencial para garantir alta revocação.
- **Contexto:** Janela de 20 documentos ($Top - K = 20$), pois não houve degradação por ruído e houve ganho de precisão.
- **Modelo:** GPT-4o-mini, dada sua superioridade em relevância e custo operacional significativamente menor.

6.3 Limitações e Trabalhos Futuros

Apesar do rigor metodológico, este estudo apresenta limitações inerentes ao seu desenho experimental. Uma restrição é a fixação de parâmetros de geração (como a temperatura em $T = 0.1$ e o *prompt* estático), uma decisão de escopo do trabalho, mas que impediu a análise de como a "criatividade" estocástica ou técnicas de engenharia de instrução poderiam refinar a resposta final. A avaliação dependente de um Juiz LLM, embora validada na literatura, também introduz potenciais vieses intrínsecos ao modelo avaliador.

Para superar essas barreiras e avançar no estado da arte, sugerem-se as seguintes linhas de investigação futura:

- **Expansão do Espaço de Hiperparâmetros:** Aplicar o DoE para investigar a influência da Temperatura e de variações na Engenharia de *Prompt* (ex: *Chain-of-Thought*), tratando-os como fatores experimentais e não apenas como constantes de controle.
- **Pré-processamento de Consultas:** Implementar e testar módulos de tratamento da pergunta do usuário antes da etapa de busca, utilizando técnicas de *Query Rewriting* ou expansão de consulta para mitigar o desalinhamento vocabular e melhorar a recuperação.
- **Comparativo com LLM Puro:** Realizar um estudo de base (*baseline*) que contraste o desempenho do sistema RAG otimizado contra o uso direto de modelos (GPT-4o) sem acesso a contexto externo. Isso permitirá quantificar o ganho real de especificidade jurídica e a redução percentual de alucinações que o RAG proporciona ao MPES.
- **Refinamento de Recuperação:** Explorar técnicas de *Re-ranking* neural com *Cross-Encoders* para reordenar a lista de documentos recuperados, buscando um compromisso entre a precisão adicional e a latência de inferência.
- **Validação Humana:** Conduzir testes qualitativos com promotores e servidores do MPES para aferir a utilidade percebida da ferramenta e a fluidez da interação em cenários reais de trabalho.

Declarações

Contribuições dos Autores

HCQ contribuiu com a concepção do estudo, desenvolvimento do software e escrita. DRCD contribuiu com a orientação metodológica e revisão.

Conflito de Interesses

Os autores declaram que não têm nenhum conflito de interesses.

Disponibilidade de Dados

Os dados e códigos criados neste estudo serão disponibilizados mediante solicitação.

Uso de Ferramentas de IA

Em conformidade com as diretrizes de integridade acadêmica, declara-se que ferramentas de IA Generativa (especificamente a família de modelos *GPT-4*) foram empregadas como componentes estruturais e de suporte a esta pesquisa em quatro frentes principais:

- **Geração de Dados Sintéticos:** Utilizou-se o modelo *GPT-4o* para a construção do *Golden Set*, gerando perguntas e respostas ideais a partir de documentos reais do MPES para garantir a diversidade do conjunto de teste.
- **Motor de Inferência RAG:** Os modelos atuaram como agentes geradores do pipeline RAG, sintetizando respostas jurídicas submetidas ao experimento fatorial.
- **Avaliação Automatizada (*LLM-as-a-Judge*):** O framework *Ragas* empregou o modelo *GPT-4o* como juiz para o cálculo das métricas de fidelidade, relevância e correitude [Es et al., 2023b].
- **Assistência à Pesquisa e Redação:** Ferramentas de IA foram utilizadas no suporte à revisão bibliográfica, auxílio na estruturação de strings de busca para bases científicas, revisão gramatical e refinamento estilístico de trechos do texto final.

Ressalta-se que o uso de tais ferramentas serviu como suporte técnico e analítico, permanecendo a responsabilidade pela interpretação dos dados, validade das fontes citadas e redação intelectual final integralmente a cargo dos autores.

Referências

- Bengio, Y., Ducharme, R., Vincent, P., and Jauvin, C. (2003). A neural probabilistic language model. *Journal of machine learning research*, 3(Feb):1137–1155.
- Chase, H. (2023). *LangChain: Building applications with LLMs through composability*. Acessado em: 23 jan. 2026.
- Cormack, G. V., Clarke, C. L., and Buettcher, S. (2009). Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval*, pages 758–759.
- de Aquino, I. V., dos Santos, M. M., Dorneles, C. F., and Carvalho, J. T. (2024). Extracting information from brazilian legal documents with retrieval augmented generation. In *Companion Proceedings of the 39th Brazilian Symposium on Data Bases*, Florianópolis, SC. Artigo aceito para publicação.
- Dunn, O. J. (1961). Multiple comparisons among means. *Journal of the American Statistical Association*, 56(293):52–64.
- Elkin, L. A., Kay, M., Higgins, J. J., and Wobbrock, J. O. (2021). An aligned rank transform procedure for multifactor contrast tests. In *The 34th Annual ACM Symposium on User Interface Software and Technology, UIST '21*, page 754–768, New York, NY, USA. Association for Computing Machinery.
- Es, S., James, J., Espinosa-Anke, L., and Schockaert, S. (2023a). Ragas: Automated evaluation of retrieval augmented generation.

- Es, S., James, J., Espinosa-Anke, L., and Schockaert, S. (2023b). Ragas: Automated evaluation of retrieval augmented generation.
- Gradients, E. (2024). *Ragas: Evaluation Framework for your RAG Pipelines*. Exploding Gradients. Acessado em: 23 jan. 2026.
- Gupta, S., Ranjan, R., and Singh, S. N. (2024). A comprehensive survey of retrieval-augmented generation (rag): Evolution, current landscape and future directions. *arXiv preprint arXiv:2404.10981*.
- Harris, Z. S. (1954). Distributional structure. *Word*, 10(2-3):146–162.
- Ji, Z., Lee, N., Frieske, R., Yu, T., et al. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38.
- Johnson, A., Smith, B., and Doe, J. (2023). Retrieval-augmented generation in healthcare: A scoping review. *Journal of Biomedical Informatics*, 145:104456.
- Jurafsky, D. and Martin, J. H. (2024). *Speech and language processing*. Pearson. 3rd ed. draft.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., et al. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474.
- Lin, C.-Y. (2004). ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out*, pages 74–81, Barcelona, Spain. Association for Computational Linguistics.
- Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Liang, P., and Manning, C. D. (2024). Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics*.
- Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., and Liang, P. (2023). Lost in the middle: How language models use long contexts.
- Manning, C. D., Raghavan, P., and Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.
- Ministério Público do Estado do Espírito Santo (2024). Consulta de legislação compilada. <https://mpes.legislacaocompilada.com.br/consulta-legislacao.aspx>. Acesso em: 23 jul. 2025.
- Montgomery, D. C. (2017). *Design and Analysis of Experiments*. John Wiley & Sons, 9th edition.
- MPES (2026). Consulta de legislação compilada. <https://mpes.legislacaocompilada.com.br/consulta-legislacao.aspx?situacao=1&interno=0>. Acessado em: 23 jan. 2026.
- OpenAI (2023). *tiktoken: A fast BPE tokeniser for use with OpenAI’s models*. Acessado em: 23 jan. 2026.
- OpenAI (2024). New embedding models and api updates. <https://openai.com/index/new-embedding-models-and-api-updates/>. Acessado em: 23 jan. 2026.
- Papineni, K., Roukos, S., Ward, T., and Zhu, W.-J. (2002). Bleu: a method for automatic evaluation of machine translation. In Isabelle, P., Charniak, E., and Lin, D., editors, *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, pages 311–318, Philadelphia, Pennsylvania, USA. Association for Computational Linguistics.
- Reitz, K. (2023). *Requests: HTTP for Humans*. Acessado em: 23 jan. 2026.
- Robertson, S. E., Walker, S., Jones, S., Hancock-Beaulieu, M. M., and Gatford, M. (1995). Okapi at trec-3. In *Overview of the Third Text REtrieval Conference (TREC-3)*, pages 109–126.
- Sparck Jones, K. (1972). A statistical interpretation of term specificity and its application in retrieval. *Journal of documentation*.
- Team, C. (2023). *Chroma: The AI-native open-source embedding database*. Acessado em: 23 jan. 2026.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., et al. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems*, pages 5998–6008.
- Wang, X., Wang, Z., Gao, X., Zhang, F., et al. (2024). Searching for best practices in retrieval-augmented generation.

- Wobbrock, J. O., Findlater, L., Gergle, D., and Higgins, J. J. (2011a). The aligned rank transform for nonparametric factorial analyses using only anova procedures. In *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*, pages 143–146. ACM.
- Wobbrock, J. O., Findlater, L., Gergle, D., and Higgins, J. J. (2011b). The aligned rank transform for nonparametric factorial analyses using only anova procedures. In *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*, CHI '11, page 143–146, New York, NY, USA. Association for Computing Machinery.
- Yu, Y., Zhuang, H., Zhang, J., Meng, Y., Ratner, A., Shang, J., Han, J., and He, C. (2024). Rankrag: Unifying context ranking with retrieval-augmented generation in llms.
- Zhang, Y., Li, H., and Chen, X. (2024a). The power of chunking: How different strategies affect rag performance. *arXiv preprint arXiv:2409.14924*.
- Zhang, Y., Li, H., and Chen, X. (2024b). The power of chunking: How different strategies affect rag performance. *arXiv preprint arXiv:2409.14924*.
- Zhao, H., Zhao, C., Li, Y., Zhang, Z., and Liu, G. (2025). Thinking in a crowd: How auxiliary information shapes llm reasoning.
- Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., et al. (2023). Judging llm-as-a-judge with mt-bench and chatbot arena.

A Prompts Utilizados no Experimento

Para garantir a reprodutibilidade e transparência deste estudo, apresentamos a seguir a transcrição integral dos *prompts* utilizados.

A.1 Prompt para Geração de Dados Sintéticos (Golden Set)

Este prompt foi utilizado para instruir o modelo GPT-4o a atuar como um analista de dados e gerar as 100 perguntas de teste.

System Instruction: Gerador de Dados Sintéticos

CONTEXTO E PERSONA

Você é um analista de dados e especialista em legislação, encarregado de criar um rigoroso conjunto de avaliação para um sistema de chatbot de Inteligência Artificial (RAG). Sua tarefa é analisar os documentos legais do Ministério Público do Espírito Santo (MP-ES) fornecidos abaixo e gerar um conjunto diversificado e desafiador de pares de pergunta e resposta.

SIMULAÇÃO DE COMPORTAMENTO DO USUÁRIO

Formule as perguntas do ponto de vista de um usuário real que **NÃO SABE** em qual documento ou link a resposta se encontra.

- As perguntas devem ser naturais e gerais.
- **NUNCA** inclua o link da fonte ou qualquer nome de arquivo no texto da pergunta.
- A fonte (o link) deve ser usada **APENAS** para preencher o campo "source" no JSON de saída.

TAREFA PRINCIPAL

Com base **EXCLUSIVAMENTE** no conteúdo dos documentos fornecidos, gere um total de **40 perguntas**, divididas igualmente entre as 4 categorias a seguir (10 perguntas por categoria):

1. **FATUAL:** "Qual o prazo para a interposição de recursos?".
2. **SÍNTESE:** "Quais são as diferenças entre os procedimentos de férias e licença-prêmio?".
3. **PROCEDIMENTAL:** "Descreva o procedimento para solicitar o teletrabalho.".
4. **AGULHA NO PALHEIRO:** "Qual o valor exato do auxílio-alimentação citado?".

FORMATO DA SAÍDA

Sua resposta final deve ser **APENAS** um array JSON válido, sem introduções, seguindo o esquema abaixo.

Esquema JSON Esperado (Output)

```
[
  {
    "id": "ID_UNICO",
    "category": "NOME_DA_CATEGORIA",
    "question": "TEXTO DA PERGUNTA (GERAL)",
    "ground_truth_answer": "RESPOSTA COMPLETA E IDEAL",
    "evidence_quote": "CITACAO EXATA DO DOCUMENTO",
    "source": "http://link.da.fonte.gov.br/documento"
  }
]
```

Nota: O conteúdo dos documentos reais foi inserido dinamicamente no final do prompt durante a execução do script.

A.2 System Prompt do Assistente RAG

Este é o comando de instrução (*system role*) passado ao modelo durante a fase de inferência.

System Role: Assistente Jurídico MPES

"Você é um Assistente Jurídico Virtual do Ministério Público do Estado do Espírito Santo. Sua função é auxiliar servidores e cidadãos a entenderem os atos normativos da instituição.

Diretrizes de Resposta:

- Baseie sua resposta **EXCLUSIVAMENTE** no contexto fornecido (trechos recuperados). Não use seu conhecimento prévio para inventar leis.
- Sempre cite a fonte normativa (ex: 'Conforme o Art. 5º da Portaria Nº 123...').
- Se o contexto não contiver a informação necessária, diga: *'Desculpe, o contexto recuperado não contém informações suficientes sobre este tema.'* Não tente adivinhar.
- Mantenha um tom formal, objetivo e impessoal."

B Interface do Portal de Legislação do MPES

A Figura 9 apresenta a interface de busca e os diversos filtros (como espécie normativa, tema, situação e autor) do portal oficial de legislação do MPES. Esta interface foi utilizada como fonte primária para o processo de *web scraping* e composição do *corpus* documental deste trabalho.

Q O que você está procurando?

Atualizado em: 29/01/2026

Termos da busca...

Selecione

Selecione

ESPÉCIE NORMATIVA

Selecione

NÚMERO

ANO

SITUAÇÃO

Selecione

AUTOR

Selecione

Incluir Atos Internos

PERÍODO

00/00/0000

00/00/0000

ORIGEM

Selecione

MODO

Selecione

NÚMERO DA PROPOSIÇÃO

TEMA PRINCIPAL

Selecione um ou mais temas

● MENOS OPÇÕES

BUSCAR

Consultas rápidas

ESPÉCIE NORMATIVA

Consulte a legislação por espécie.

TEMA

Consulte a legislação por tema.

SITUAÇÃO

Consulte a legislação por situação.

AUTOR

Consulte a legislação por autor.

ÍNDICE CRONOLÓGICO

Consulte a legislação por ano.

Figura 9: Captura de tela do Portal de Legislação Online do MPES.

27

C Interface da Assistente Virtual Fabi

A Figura 10 ilustra o ambiente de testes da assistente virtual Fabi. A interface permite que o usuário realize perguntas em linguagem natural e receba respostas sintetizadas que incluem a citação direta das fontes normativas consultadas, garantindo a rastreabilidade da informação.



Figura 10: Interface de interação da assistente Fabi desenvolvida com o framework Gradio.

D Interface de Documentação da API (Swagger UI)

A Figura 11 apresenta a interface de documentação interativa (Swagger UI) gerada automaticamente pelo *framework* FastAPI para o orquestrador do sistema RAG. A imagem detalha o *endpoint* de requisição principal (POST `/responder`) e o esquema de dados JSON (*payload*) utilizado para parametrizar as inferências, permitindo o controle rigoroso de hiperparâmetros experimentais como `top_k`, `chunking_strategy`, `search_type` e o modelo gerador (`model`).




Figura 11: Interface de documentação da API do Chatbot MPES, destacando os parâmetros do *endpoint* de resposta.