

Análise de Hiperparâmetros em Sistemas de Geração Aumentada por Recuperação Aplicado ao Acervo do MPES

Hyperparameter Analysis in Retrieval-Augmented Generation (RAG) Systems Applied to the MPES Corpus

Heitor Coitinho Quartezani   [Departamento de Estatística |Universidade Federal do Espírito Santo (UFES)]
Diego Roberto Colombo Dias  [Departamento de Estatística |Universidade Federal do Espírito Santo (UFES)]

✉ Departamento de Estatística, Centro de Ciências Exatas, UFES, Vitória, ES, Brasil.

Resumo. Este projeto de pesquisa propõe uma metodologia fundamentada em *Design of Experiments* (DoE) para analisar e otimizar os hiperparâmetros de um sistema de *Retrieval-Augmented Generation* (RAG) aplicado ao acervo normativo do Ministério Público do Estado do Espírito Santo (MPES). O objetivo central é identificar o impacto estatisticamente significativo de fatores críticos, como a estratégia de segmentação de documentos (*chunking*), o volume de contexto recuperado (k) e a escolha do *Large Language Model* (LLM) — na qualidade das respostas geradas. A avaliação utiliza o paradigma *LLM-as-a-Judge* com o suporte do framework *Ragas*. Devido à natureza não-paramétrica dos dados, a análise estatística é conduzida via Transformação de Postos Alinhados (*Aligned Rank Transform - ART*). Os resultados revelam que, embora o modelo de linguagem seja o fator de maior peso na precisão, a interação entre o tamanho do *chunk* e a técnica de busca desempenha um papel crucial na mitigação de alucinações, indicando que configurações maiores de k nem sempre resultam em ganhos marginais de fidelidade.

Abstract. This research project proposes a *Design of Experiments* (DoE) methodology to analyze and optimize the hyperparameters of a *Retrieval-Augmented Generation* (RAG) system applied to the document corpus of the Public Prosecutor's Office of the State of Espírito Santo (MPES). The main objective is to identify which factors, such as the document *chunking* strategy, the number of retrieved documents (k), and the *Large Language Model* (LLM) used, have a statistically significant impact on the system's response quality. Quality will be measured automatically through the *LLM-as-a-Judge* paradigm, using metrics from the *Ragas* framework. The statistical analysis will be conducted using the *Aligned Rank Transform* (ART) technique, a robust non-parametric approach for factorial designs, to provide a quantitative guide for configuring more efficient RAG systems.

Palavras-chave: Geração Aumentada por Recuperação, Desenho de Experimentos, Otimização de Hiperparâmetros, LLM-as-a-Judge, Análise de Variância.

Keywords: Retrieval-Augmented Generation, Design of Experiments, Hyperparameter Optimization, LLM-as-a-Judge, Analysis of Variance.

Recebido/Received: DD Month YYYY • **Aceito/Accepted:** DD Month YYYY • **Publicado/Published:** DD Month YYYY

1 Introdução

Nos últimos anos, os *Large Language Models* (LLMs), ou Grandes Modelos de Linguagem, revolucionaram a interação humano-computador ao oferecer interfaces em linguagem natural capazes de sintetizar grandes volumes de informação [Gao *et al.*, 2024] e [Wu *et al.*, 2025]. No entanto, a utilidade dessas ferramentas é controversa, devido à tendência dos modelos em inventar informação que parece ser verdadeira [Ji *et al.*, 2023].

O cenário que motivou este estudo originou-se de uma limitação operacional crítica no Ministério Público do Estado do Espírito Santo (MPES). Embora a instituição possuísse um vasto acervo de atos normativos e portarias digitalizados [Ministério Público do Estado do Espírito Santo, 2026], esse *corpus* carecia de qualquer mecanismo estruturado de indexação ou recuperação. Inexistia, até o momento do projeto, sequer um sistema básico de busca por palavras-chave. Consequentemente, o acesso à informação dependia exclusivamente do conhecimento tácito prévio, pois o usuário precisava saber antecipadamente em qual documento específico a norma ou fato residia para encontrá-la.

Diante dessa barreira de acessibilidade, onde o acervo existia mas era invisível para fins de consulta exploratória, a implementação de um sistema inteligente não surgiu apenas como uma modernização, mas como uma necessidade para desbloquear o valor informacional desse acervo latente. Para endereçar esse problema, optou-se pela arquitetura *Retrieval-Augmented Generation* (RAG), ou Geração Aumentada por Recuperação.

A relevância e a rápida evolução desta arquitetura são evidenciadas por revisões abrangentes da literatura, que a posicionam como a solução padrão para conectar LLMs a dados privados [Gupta *et al.*, 2024; Wu *et al.*, 2025]. Contudo, o desempenho de um sistema RAG é altamente sensível a hiperparâmetros como a estratégia de *chunking*, ou segmentação, e o número de documentos recuperados (k). A busca por configurações ótimas é um campo de pesquisa ativo, pois escolhas subótimas podem levar a respostas irrelevantes ou alucinações [Wang *et al.*, 2024].

Este projeto propõe uma abordagem sistemática para configurar esse *pipeline* no MPES ao utilizar uma metodologia estatística robusta para transformar um acervo antes

inacessível em uma base de conhecimento consultável e confiável.

1.1 Objetivos

O objetivo geral deste trabalho é desenvolver e aplicar uma metodologia de *Design of Experiments* (DoE), ou Desenho de Experimentos, para analisar sistematicamente e otimizar os hiperparâmetros de um sistema RAG aplicado ao acervo do MPES. Busca-se identificar os fatores que exercem influência estatisticamente significativa na qualidade das respostas geradas.

Para alcançar o objetivo geral, os seguintes objetivos específicos serão perseguidos:

- Avaliar o impacto de quatro estratégias de *chunking* ao comparar abordagens recursivas e semânticas.
- Comparar a eficácia de métodos de recuperação vetorial, lexical via *Best Matching 25* (BM25) e híbrida via *Reciprocal Rank Fusion* (RRF), ou Fusão de Classificação Recíproca.
- Analisar o comportamento do sistema ao variar o número de documentos recuperados (k) e buscar o ponto de equilíbrio entre contexto e ruído.
- Quantificar o ganho de desempenho entre modelos de diferentes classes de complexidade, especificamente GPT-4o mini e GPT-4o.

1.2 Justificativa

A escolha da arquitetura RAG para resolver o problema de acessibilidade do MPES fundamenta-se na insuficiência das abordagens tradicionais. Dada a inexistência prévia de qualquer mecanismo de busca, a implementação de uma busca puramente lexical por palavras-chave resolveria apenas parcialmente o problema, pois falharia em capturar consultas conceituais ou semânticas típicas do domínio jurídico. Por outro lado, o uso direto de LLMs seria inviável devido à impossibilidade de treinar o modelo com dados privados em tempo real e ao risco inaceitável de alucinações [Lewis *et al.*, 2020]. O RAG oferece o equilíbrio necessário ao ancorar a geração em documentos reais do MPES e garantir rastreabilidade e precisão factual.

Entretanto, a literatura indica que a configuração desses sistemas é frequentemente realizada de maneira empírica, por tentativa e erro, carecendo de um guia sistemático para a escolha de hiperparâmetros. A ausência de uma análise quantitativa rigorosa dificulta a compreensão de quais hiperparâmetros realmente impactam a performance [Wang *et al.*, 2024]. A aplicação do DoE justifica-se por oferecer uma abordagem formal para substituir o empirismo por evidência estatística, o que permite identificar a configuração ótima que maximiza a fidelidade da informação entregue ao usuário [Montgomery, 2017].

Institucionalmente, o trabalho justifica-se por transformar um acervo documental estático e inacessível em uma ferramenta dinâmica de suporte à decisão.

2 Fundamentação Teórica

Este capítulo estabelece o arcabouço teórico do estudo e ancora-se na literatura clássica de *Natural Language Processing* (NLP) Jurafsky and Martin [2024] e de *Information Retrieval* (IR) Manning *et al.* [2008]. Para conferir rigor à

análise dos hiperparâmetros, detalha-se a natureza probabilística dos modelos de linguagem, os algoritmos matemáticos de IR e o formalismo estatístico do DoE Montgomery [2017].

2.1 Modelos de Linguagem e a Arquitetura Transformer

A base de qualquer sistema RAG é o LLM. Conforme definido por Jurafsky and Martin [2024], para compreender as limitações que motivam este estudo, como a tendência à "alucinação" factual, é fundamental desmistificar o modelo como um agente cognitivo e analisá-lo sob a ótica de um processo estocástico de previsão de sequência suportado pela arquitetura *Transformer*.

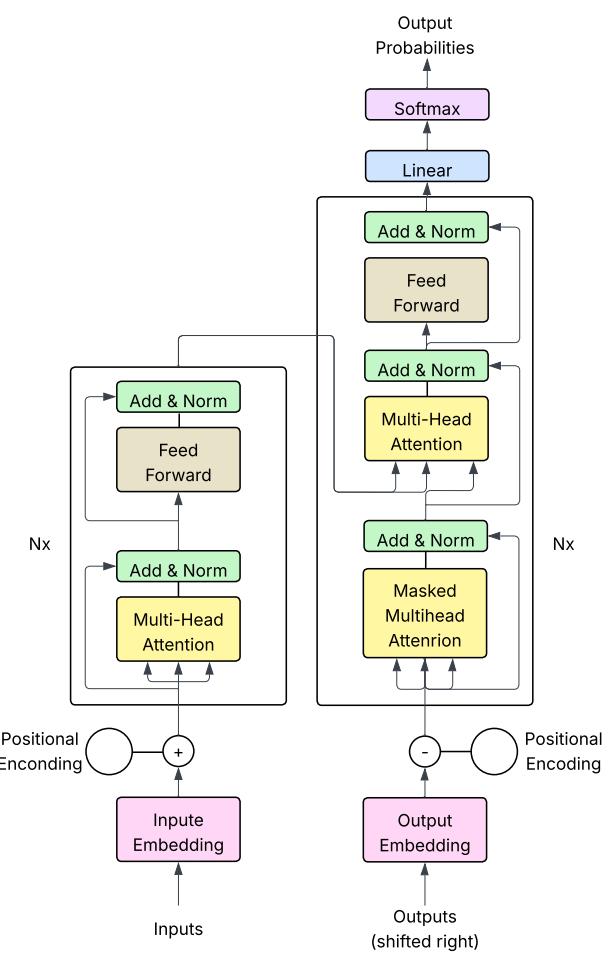


Figura 1. Arquitetura do Modelo Transformer baseado na figura de [Vaswani *et al.*, 2017].

A arquitetura do modelo *Transformer* fundamenta-se em uma estrutura de codificador (encoder) e decodificador (decoder), conforme ilustrado na Figura 1. O processo inicia-se com o tratamento das entradas por meio de camadas de Input e Output Embeddings, acompanhadas de Positional Encoding para preservar a informação sequencial. O núcleo do modelo é composto por múltiplos blocos repetidos ($N \times$) que utilizam mecanismos de atenção de múltiplas cabeças (Multi-Head Attention), incluindo uma versão com máscara no decodificador para prever tokens subsequentes. Cada subcamada é seguida por operações de normalização e conexão residual (Add & Norm) e redes neurais feed forward, culminando em camadas lineares e softmax para a geração das probabilidades

de saída.

2.1.1 O LLM como Estimador de Probabilidade

Essencialmente, um LLM é uma função paramétrica complexa P_θ treinada para estimar a distribuição de probabilidade conjunta de uma sequência de texto [Bengio *et al.*, 2003]. O processo de geração, ou inferência, é uma aplicação iterativa da regra da cadeia da probabilidade, onde o modelo prevê o próximo *token* w_t (unidade mínima de texto, como uma sílaba ou palavra) condicionado a todo o histórico anterior $C = \{w_1, \dots, w_{t-1}\}$:

$$w_t \sim P(w_t|C; \theta) \quad (1)$$

Onde θ representa os bilhões de parâmetros, ou pesos, da rede neural ajustados via gradiente descendente para maximizar a verossimilhança dos dados de treinamento.

Neste contexto, o fenômeno popularmente chamado de "alucinação" possui uma explicação probabilística: ocorre quando o modelo atribui massa de probabilidade elevada a uma sequência que é linguisticamente fluida e coerente com o contexto, ou seja, possui alta probabilidade sintática, mas que não corresponde a um fato real [Ji *et al.*, 2023]. O sistema RAG atua justamente ao alterar o contexto C e injetar evidências externas para condicionar a probabilidade em direção a fatos recuperados.

2.1.2 O Mecanismo de Atenção

A capacidade dos LLMs modernos de processar contextos longos e entender nuances jurídicas deve-se à arquitetura *Transformer* introduzida por Vaswani *et al.* [2017]. Modelos anteriores, como as *Recurrent Neural Networks* (RNNs), processavam o texto sequencialmente, o que causava dificuldades na manutenção de dependências de longo prazo em parágrafos extensos, um problema inerente à natureza recursiva dessas redes [Jurafsky and Martin, 2024].

O *Transformer* resolve isso através do mecanismo de *Self-Attention*, ou Autoatenção. Este mecanismo permite que o modelo processe todos os *tokens* da entrada simultaneamente e aprenda a ponderar a importância de cada palavra em relação às outras. Para cada *token*, o modelo aprende três vetores:

- **Query (Q):** A "pergunta" que o *token* faz (ex: um verbo procurando seu sujeito).
- **Key (K):** A "etiqueta" que o *token* oferece para ser encontrado.
- **Value (V):** O conteúdo informacional do *token*.

O peso da atenção é calculado pela similaridade entre a Pergunta (Q) e as Chaves (K) de todos os outros *tokens*. Matematicamente, aplica-se o produto escalar normalizado seguido de uma função *Softmax*:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2)$$

O resultado é uma média ponderada dos valores V . Isso permite, por exemplo, que ao processar a palavra "Artigo" em um texto jurídico, o modelo atribua peso quase total ao número da lei subsequente e ignore ruídos intervenientes.

2.1.3 Controle de Entropia via Temperatura

A etapa final de um LLM converte os valores brutos da rede, os *logits* (z_i), em probabilidades normalizadas. Isso é feito através da função *Softmax* parametrizada por um hiperparâmetro crítico para este estudo: a **Temperatura (T)**.

$$P(w_i) = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)} \quad (3)$$

Segundo Holtzman *et al.* [2019], a temperatura atua como um regulador de entropia da distribuição:

- **Se $T \rightarrow 0$:** A distribuição torna-se um *argmax* determinístico. O modelo sempre escolhe o *token* mais provável. No contexto jurídico deste trabalho, fixou-se $T = 0.1$ para garantir reproduzibilidade e minimizar a criatividade, ou alucinação.
- **Se $T \rightarrow 1$:** A distribuição achata-se e permite que o modelo amostra *tokens* menos prováveis, o que gera textos mais diversos mas menos confiáveis.

2.2 Sistemas de Recuperação de Informação

A arquitetura RAG, formalizada por Lewis *et al.* [2020], depende intrinsecamente da capacidade de recuperar um subconjunto de documentos $Z \subset D$ que seja semanticamente relevante para a consulta do usuário q . A eficácia da resposta final do LLM é limitada superiormente pela qualidade desses documentos recuperados, conforme o princípio *Garbage In, Garbage Out* [Zhao *et al.*, 2025]. Este trabalho avalia e combina dois paradigmas distintos de recuperação: a busca vetorial densa e a busca lexical esparsa.

2.2.1 Recuperação Vetorial e Embeddings

A recuperação vetorial fundamenta-se na *Distributional Hypothesis*, ou Hipótese Distribucional, de Harris [1954] ao mapear unidades textuais para vetores em um espaço latente contínuo \mathbb{R}^n . Para este estudo, utiliza-se o modelo *text-embedding-3-small* [OpenAI, 2024], que projeta textos em $n = 1536$ dimensões.

Geometricamente, o treinamento desses modelos busca otimizar a disposição espacial de tal forma que a proximidade angular reflete a similaridade semântica. Diferente da distância Euclidiana, que é sensível à magnitude e portanto ao tamanho do documento, utiliza-se a **Similaridade de Cosseno**, métrica padrão em IR [Manning *et al.*, 2008] que mensura apenas o alinhamento de orientação entre os vetores:

$$\text{sim}(\vec{q}, \vec{d}) = \cos(\theta) = \frac{\vec{q} \cdot \vec{d}}{\|\vec{q}\| \cdot \|\vec{d}\|} \quad (4)$$

Esta abordagem captura sinônima e relações conceituais, como aproximar "sanção" de " pena", e supera a necessidade de correspondência exata de palavras.

2.2.2 Recuperação Lexical Probabilística

Apesar da robustez semântica dos vetores, eles podem falhar em capturar termos exatos cruciais no domínio jurídico, como o número de uma lei ("8.666") ou um nome próprio. Para isso, utiliza-se a recuperação lexical.

A base teórica é a estatística de frequência. Uma abordagem ingênua seria contar a Frequência do Termo (*TF*).

Contudo, palavras funcionais como "o", "de" ou "para" são extremamente frequentes e carregam pouca informação discriminativa. Para corrigir isso, a Teoria da Informação introduz a *Inverse Document Frequency* (IDF), ou Frequência Inversa de Documento, proposta originalmente por Sparck Jones [1972] para penalizar termos comuns e valorizar termos raros:

$$IDF(t) = \log \left(\frac{N - n(t) + 0.5}{n(t) + 0.5} \right) \quad (5)$$

Onde N é o total de documentos no *corpus* e $n(t)$ é o número de documentos contendo o termo t .

O algoritmo adotado, o *Okapi BM25* [Robertson et al., 1995], é uma evolução robusta do TF-IDF que introduz saturação. Diferente da contagem simples onde a relevância cresce linearmente com a repetição da palavra, o BM25 aplica uma curva assintótica controlada pelo parâmetro k_1 . Além disso, normaliza o *score* pelo tamanho do documento ($|d|$) em relação à média do *corpus* ($avgdl$) via parâmetro b :

$$\begin{aligned} Score(d, q) = & \sum_{t \in q} IDF(t) \cdot \\ & f(t, d) \cdot (k_1 + 1) \\ & \frac{f(t, d) + k_1 \cdot (1 - b + b \cdot \frac{|d|}{avgdl})}{\text{fator}} \end{aligned} \quad (6)$$

Essa formulação probabilística justifica o uso do BM25 como o componente de precisão cirúrgica do sistema.

2.2.3 Fusão Híbrida de Rankings

A combinação das buscas Vetorial e Lexical não é trivial, pois suas distribuições de pontuação são incompatíveis. O Cosseno varia em $[-1, 1]$, enquanto o BM25 varia em $[0, \infty)$ sem limite superior definido.

Para unificar essas abordagens sem depender de normalizações sensíveis a *outliers*, utiliza-se o algoritmo RRF proposto por Cormack et al. [2009]. Este método é não-paramétrico e ignora os valores absolutos dos *scores* ao basear-se apenas na posição, ou posto, do documento em cada lista ordenada. O *score* final é dado pela soma harmônica dos inversos dos *ranks*:

$$RRF score(d) = \sum_{j \in S} \frac{1}{\eta + r_j(d)} \quad (7)$$

Onde S é o conjunto de sistemas (Vetorial, Lexical), $r_j(d)$ é a posição ordinal do documento d no sistema j , e η é uma constante de suavização definida como 60 neste trabalho. O RRF penaliza documentos que aparecem no topo de apenas uma lista e favorece fortemente aqueles consensualmente relevantes em ambos os métodos [Yu et al., 2024].

2.3 Estratégias de Segmentação e Continuidade Semântica

A indexação vetorial exige a discretização de documentos longos em unidades menores, denominadas *chunks*. A definição da granularidade dessa discretização não é trivial e estabelece um *trade-off*, ou compromisso, entre a densidade de informação (sinal) e o ruído contextual.

Conforme Zhang et al. [2024a], a segmentação impacta a probabilidade de recuperação $P(Z|q)$ de duas formas antagônicas:

- **Granularidade Fina (Small Chunks):** Maximiza a similaridade de cosseno para fatos específicos, mas fragmenta unidades de raciocínio e rompe correferências e elipses necessárias para a compreensão do modelo.

- **Granularidade Grossa (Large Chunks):** Preserva a coerência global, mas dilui a representação vetorial e reduz a distinção entre tópicos vizinhos, pois o vetor torna-se uma média do documento e perde especificidade.

2.3.1 Segmentação Recursiva e Janelas Deslizantes

A abordagem heurística padrão, denominada Segmentação Recursiva, discretiza o texto baseando-se em delimitadores sintáticos como parágrafos ou quebras de linha e um limite fixo de caracteres L .

A principal limitação teórica deste método é a imposição de fronteiras arbitrárias que podem seccionar sentenças ou argumentos lógicos. Para mitigar a perda de informação nas bordas (*boundary loss*), aplica-se a técnica de *Overlap*, ou Janela Deslizante com Sobreposição. Seja C_i o i -ésimo *chunk* de comprimento L e O o tamanho da sobreposição, o início do *chunk* C_{i+1} é deslocado por $L - O$ em relação a C_i .

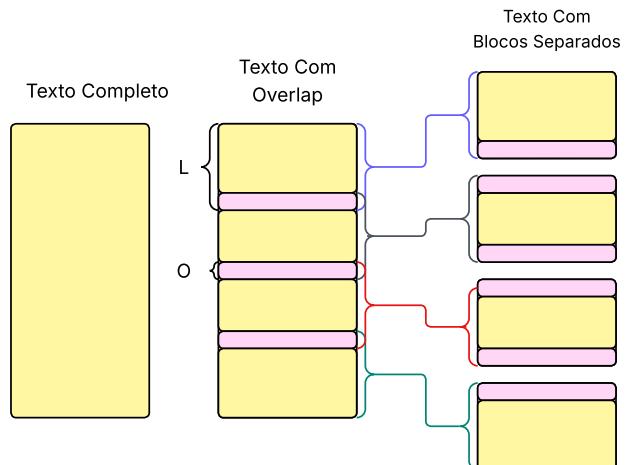


Figura 2. Segmentação com Janela Deslizante

A Figura 2 ilustra o processo de segmentação recursiva usando *Overlap*. O texto completo é separado em segmentos de tamanho L , havendo sobreposição entre os segmentos de tamanho O .

Essa redundância intencional ($O > 0$) garante a continuidade semântica e assegura que termos localizados no final de um segmento possuam contexto à direita na janela subsequente. Neste trabalho, avaliam-se janelas com O proporcional a 20% de L .

2.3.2 Segmentação Semântica

Em contraste com a heurística sintática, a Segmentação Semântica propõe uma abordagem orientada aos dados. O método baseia-se na premissa de que mudanças de tópico no texto correspondem a grandes distâncias angulares no espaço vetorial.

O algoritmo opera calculando a similaridade de cosseno $sim(s_t, s_{t+1})$ entre sentenças sequenciais. Formalmente, define-se um ponto de corte, ou fronteira do *chunk*, no índice t se a dissimilaridade exceder um limiar crítico τ :

$$1 - sim(s_t, s_{t+1}) > \tau \quad (8)$$

Onde τ é tipicamente definido como um percentil (ex: 95) da distribuição de distâncias do documento. Esta abordagem agrupa sentenças semanticamente coesas, minimiza a variância intra-chunk e maximiza a variância inter-chunk.

2.4 Avaliação Automatizada e Métricas

Para superar as limitações das métricas baseadas em n-gramas, como BLEU [Papineni et al., 2002] e ROUGE [Lin, 2004], este trabalho adota o paradigma *LLM-as-a-Judge* [Zheng et al., 2023] utilizando o framework *Ragas*. A avaliação combina métricas sem referência (*reference-free*), fundamentadas teoricamente por Es et al. [2023], e métricas baseadas em referência (*ground truth*), implementadas conforme a documentação técnica da biblioteca [Gradients, 2024].

2.4.1 Faithfulness (Fidelidade)

A métrica de *Faithfulness* mensura a consistência factual da resposta gerada em relação ao contexto recuperado. O objetivo é garantir que a resposta não contenha "alucinações", ou seja, informações que não podem ser deduzidas dos documentos fornecidos.

Conforme detalhado na documentação do *Ragas* [Exploding Gradients, 2024d], o cálculo é realizado em duas etapas sequenciais utilizando um LLM:

- Geração de Afirmações:** A resposta gerada (A) é decomposta em um conjunto de afirmações atômicas ($S = \{s_1, s_2, \dots, s_n\}$). Isso isola cada proposição factual contida no texto.
- Verificação de Suporte:** Para cada afirmação s_i , o modelo verifica se ela pode ser inferida lógica e exclusivamente a partir do contexto recuperado (C).

O *score* de fidelidade é calculado pela razão entre o número de afirmações suportadas e o número total de afirmações extraídas:

$$\text{Faithfulness} = \frac{|V|}{|S|} \quad (9)$$

Onde $|V|$ representa a contagem de afirmações verificadas como verdadeiras com base no contexto e $|S|$ é o total de afirmações geradas.

2.4.2 Answer Relevancy (Relevância da Resposta)

A métrica de *Answer Relevancy* avalia a pertinência da resposta gerada em relação ao *input* do usuário. Conforme a documentação oficial do *Ragas* [Exploding Gradients, 2025], esta é uma métrica *reference-free* (sem gabarito) que não julga a veracidade factual, mas sim se a resposta endereça a pergunta de forma direta e apropriada, penalizando respostas incompletas ou que contenham detalhes redundantes.

O algoritmo opera sob a premissa de que, se uma resposta for verdadeiramente relevante, deve ser possível reconstruir a pergunta original a partir dela. O cálculo segue três etapas:

- Geração de Perguntas Artificiais:** Um LLM analisa a resposta gerada (A) e cria um conjunto de N perguntas prováveis (Q_{gi}) que poderiam ter motivado aquela resposta. Por padrão, $N = 3$.
- Embeddings:** O sistema converte tanto a pergunta original do usuário (Q_o) quanto as perguntas geradas artificialmente (Q_{gi}) em vetores de *embedding*.

- Cálculo de Similaridade:** Calcula-se a similaridade de cosseno entre o vetor da pergunta original (E_o) e os vetores das perguntas geradas (E_{gi}).

O *score* final é a média aritmética dessas similaridades:

$$\text{Answer Relevancy} = \frac{1}{N} \sum_{i=1}^N \cos(E_{gi}, E_o) \quad (10)$$

Valores próximos de 1 indicam alto alinhamento entre a intenção da pergunta e o conteúdo da resposta, enquanto valores baixos sugerem que a resposta desviou do tópico ou é excessivamente genérica.

2.4.3 Context Precision (Precisão do Contexto)

A métrica de *Context Precision* avalia a qualidade do ordenamento (*ranking*) realizado pelo sistema de recuperação. Diferente de métricas estáticas que apenas verificam a presença da informação, esta métrica mensura se os documentos mais relevantes foram priorizados no topo da lista, o que é crítico para o desempenho de LLMs devido ao viés de primazia.

Conforme a definição formal do framework *Ragas* [Exploding Gradients, 2024b], o *score* é calculado através da média da precisão em k (*Precision@k*) ponderada pela relevância posicional:

$$\text{Context Precision}@K = \frac{\sum_{k=1}^K (\text{Precision}@k \times v_k)}{\text{Total de itens relevantes no Top K}} \quad (11)$$

Onde:

- K é o número total de documentos recuperados.
- *Precision@k* é a proporção de documentos relevantes até a posição k .
- $v_k \in \{0, 1\}$ é o indicador de relevância na posição k , avaliado por um LLM comparando o documento com o gabarito oficial (*reference*).

Valores próximos de 1 indicam que todos os documentos relevantes para responder à pergunta foram apresentados nas primeiras posições, minimizando o ruído contextual que antecede a informação útil.

2.4.4 Context Recall (Revocação do Contexto)

A métrica de *Context Recall* avalia a extensão em que o contexto recuperado (C) alinha-se com a resposta esperada ou *Ground Truth* (G). Conforme definido na documentação do framework *Ragas* [Exploding Gradients, 2024c], esta métrica verifica se toda a informação necessária para responder à pergunta está presente nos documentos recuperados.

O algoritmo de cálculo utiliza um LLM para realizar a auditoria sentença a sentença:

- Decomposição:** O gabarito oficial (G) é fragmentado em uma lista de sentenças ou afirmações atômicas individuais.
- Verificação de Atribuição:** Para cada sentença s_i do gabarito, o modelo verifica se ela pode ser atribuída ou deduzida a partir do contexto recuperado (C).

O *score* final é a razão entre as sentenças do gabarito que são suportadas pelo contexto e o total de sentenças do gabarito:

$$\text{Context Recall} = \frac{|\{s \in G \mid C \text{ suporta } s\}|}{|G|} \quad (12)$$

Valores próximos de 1 indicam que o sistema de recuperação trouxe todas as informações relevantes contidas na resposta ideal. Valores baixos indicam que o contexto recuperado está incompleto, obrigando o LLM a usar conhecimento paramétrico ou alucinar para responder corretamente.

2.4.5 Answer Correctness (Corretude da Resposta)

A métrica de *Answer Correctness* avalia a precisão da resposta gerada (A) em comparação direta com o gabarito oficial ou *Ground Truth* (G). Conforme a documentação oficial do framework *Ragas* [Exploding Gradients, 2024a], esta métrica emprega uma abordagem híbrida que combina avaliação semântica e factual através de uma média ponderada.

O cálculo ocorre em duas etapas distintas:

1. **Corretude Factual (Factual Correctness):** Utiliza-se um LLM para decompor tanto a resposta gerada quanto o gabarito em um conjunto de afirmações atômicas. A partir dessa decomposição, o algoritmo classifica as afirmações em três categorias:

- **TP (Verdadeiros Positivos):** Fatos presentes tanto na resposta gerada quanto no gabarito.
- **FP (Falsos Positivos):** Fatos presentes na resposta gerada, mas ausentes no gabarito (alucinação ou informação extra não solicitada).
- **FN (Falsos Negativos):** Fatos presentes no gabarito, mas omitidos na resposta gerada.

O *score* factual é calculado utilizando a fórmula do *F1-Score* modificada para conjuntos:

$$\text{Score}_{factual} = \frac{TP}{TP + 0.5 \times (FP + FN)} \quad (13)$$

2. **Similaridade Semântica (Semantic Similarity):**

Calcula-se a similaridade de cosseno entre os vetores de *embedding* da resposta gerada e do gabarito. Este componente serve como um "fator de amortecimento" para capturar a equivalência de significado global, mesmo que a fraseologia exata difira.

O *score* final de *Answer Correctness* é a média ponderada desses dois componentes, tipicamente atribuindo maior peso à corretude factual (ex: 0.75) em detrimento da similaridade puramente vetorial (ex: 0.25).

2.5 Delineamento e Modelagem

A principal contribuição metodológica deste trabalho reside na formalização do processo de avaliação de sistemas de IA. Enquanto a prática comum na Ciência da Computação envolve ajustes empíricos de hiperparâmetros via tentativa e erro, este estudo fundamenta-se na teoria do DoE para inferir causalidade e quantificar incertezas.

2.5.1 O Experimento Fatorial Completo

Para investigar como diferentes configurações afetam a qualidade do RAG, optou-se por um Delineamento Fatorial Completo (n^k). Esta abordagem testa exaustivamente todas as combinações possíveis entre os níveis dos fatores, varrendo integralmente o espaço de busca definido para os hiperparâmetros.

A escolha por este delineamento, em detrimento de métodos fracionados ou testes "um-fator-por-vez" (OFAT), justifica-se pela necessidade de robustez. Ao avaliar cada fator sob diversas condições de contorno (por exemplo, testar a Busca Híbrida sob quatro tipos diferentes de *chunking*), assegura-se que a estimativa dos efeitos principais não esteja enviesada por um cenário específico, garantindo que a configuração recomendada tenha validade geral [Montgomery, 2017].

Os fatores controlados (X) e a variável resposta (Y) definem a estrutura do experimento:

- **Fatores (Variáveis Independentes):**

1. *Estratégia de Chunking* (4 níveis): Recursiva (500:100 e 1000:200 tokens) e Semântica (Percentil 75 e 95).
2. *Tipo de Busca* (3 níveis): Vetorial, Textual (BM25) e Híbrida (RRF).
3. *Top-K* (4 níveis): 5, 10, 15, 20 documentos recuperados.
4. *Modelo LLM* (2 níveis): GPT-4o e GPT-4o-mini.

- **Variável Resposta (Dependente):** O *score* contínuo $Y \in [0, 1]$ atribuído pelo oráculo para as métricas de qualidade (*Faithfulness*, *Relevancy*, *Precision*, *Recall*, *Correctness*).

O número total de tratamentos (combinações únicas) é $4 \times 3 \times 4 \times 2 = 96$. Como cada tratamento foi replicado para 40 perguntas distintas (bloqueagem), o tamanho total da amostra é $N = 3.840$ observações experimentais.

2.5.2 Transformação de Postos Alinhados (ART)

Dada a natureza das métricas de avaliação, que são limitadas ao intervalo $[0, 1]$ e podem apresentar distribuições assimétricas, a análise estatística foi conduzida utilizando a técnica de *Aligned Rank Transform* (ART), ou Transformação de Postos Alinhados, proposta por Wobbrock *et al.* [2011].

O ART é um método não-paramétrico desenhado especificamente para a análise de experimentos fatoriais com múltiplos fatores. O procedimento metodológico consiste em três etapas sequenciais para cada termo do modelo (seja um efeito principal ou uma interação):

1. **Alinhamento:** Os dados brutos são transformados para isoler o efeito de interesse. Subtraem-se da resposta os efeitos estimados de todos os outros fatores (efeitos "ruído" para aquele teste específico), resultando nos resíduos alinhados.
2. **Rankeamento:** Aplica-se a transformação de postos (*ranking*) aos dados alinhados.
3. **Análise de Variância:** Realiza-se a Análise de Variância (F-test) sobre os postos alinhados para testar a significância estatística.

Essa abordagem possibilita o uso de procedimentos robustos de inferência estatística em dados que não atendem aos pressupostos de normalidade ou homocedasticidade, mantendo o poder de detectar nuances complexas no comportamento dos hiperparâmetros.

2.5.3 Comparações Múltiplas

A análise de variância via ART indica apenas a existência de diferenças significativas globais, mas não especifica entre quais níveis elas ocorrem. Para identificar essas diferenças pontuais (ex: se a *Busca Híbrida* é estatisticamente superior à *Busca Vetorial*), utilizou-se o método de *Aligned Rank Transform Contrasts*, ou Contrastes de Postos Alinhados, conforme proposto por Elkin *et al.* [2021].

Diferente de testes *post-hoc* paramétricos tradicionais (como Tukey [Montgomery, 2017]), este método computa as diferenças par-a-par diretamente sobre os postos alinhados, preservando a robustez não-paramétrica do delineamento fatorial.

Para assegurar o rigor estatístico e controlar a taxa de erro familiar (FWER) decorrente dos múltiplos testes simultâneos, os p-valores resultantes foram penalizados utilizando a correção de Bonferroni [Dunn, 1961]. Neste protocolo conservador, uma diferença entre configurações é considerada estatisticamente significativa apenas se o p-valor ajustado for inferior ao nível de significância $\alpha = 0.05$.

3 Trabalhos Relacionados

A rápida evolução da arquitetura RAG estimulou uma vasta produção acadêmica focada na engenharia de seus componentes e na aplicação em domínios de alta precisão. A literatura recente evidencia uma lacuna entre estudos empíricos de "melhores práticas" e a validação estatística rigorosa dessas configurações em línguas e domínios específicos.

No contexto global de otimização, Wang *et al.* [2024] conduziram uma investigação extensiva sobre a sensibilidade dos sistemas RAG a escolhas de *design* e analisaram empiricamente o impacto de estratégias de segmentação e recuperação. Embora estabeleçam diretrizes valiosas para domínios gerais, a análise baseia-se majoritariamente em estudos de ablação, ou remoção de componentes, e observação direta de métricas, sem a aplicação de um formalismo como o DoE para quantificar interações complexas entre fatores. Nossa trabalho preenche essa lacuna metodológica ao aplicar a Transformação de Postos Alinhados (ART) para validar estatisticamente essas práticas.

A granularidade da informação recuperada é outro ponto crítico. Zhang *et al.* [2024b] demonstraram que a estratégia de *chunking* afeta drasticamente a coerência semântica e sugerem que quebras baseadas em significado superam cortes recursivos simples. Estendemos essa investigação ao testar essa hipótese em textos jurídicos brasileiros, caracterizados por sentenças longas e vocabulário arcaico, um cenário onde a preservação do contexto é ainda mais desafiadora do que nos *corpora* de língua inglesa tipicamente avaliados.

Quanto à aplicação em domínios sensíveis, Johnson *et al.* [2023] consolidaram o uso de RAG na área da saúde e evidenciaram sua capacidade de reduzir alucinações em contextos críticos. No cenário nacional, de Aquino *et al.* [2024] iniciaram a exploração de RAG em documentos jurídicos brasileiros

com foco na arquitetura de extração de informações. Contudo, este estudo anterior priorizou a viabilidade técnica e a validação qualitativa. A presente pesquisa avança ao focar na otimização quantitativa dos parâmetros de recuperação e utiliza o paradigma *LLM-as-a-Judge* para auditar a fidelidade do sistema frente a um acervo legislativo não estruturado.

Por fim, no que tange às técnicas de refinamento de busca, propostas recentes como o RankRAG [Yu *et al.*, 2024] utilizam modelos neurais avançados, os *Cross-Encoders*, para reordenar documentos. Embora eficazes, esses modelos introduzem latência significativa na inferência. Em contraste, nossa pesquisa investiga a eficácia do algoritmo RRF como uma alternativa computacionalmente eficiente para fundir buscas vetoriais e lexicais, buscando um equilíbrio entre precisão e custo computacional viável para instituições públicas.

A revisão da literatura revela que, embora existam diretrizes gerais para a construção de sistemas RAG, a maioria dos estudos adota uma abordagem de engenharia empírica, ou "melhores práticas", baseada na observação direta de métricas de desempenho sem o suporte de testes de hipóteses formais. Além disso, as soluções desenvolvidas para o contexto jurídico brasileiro focam predominantemente na viabilidade arquitetural e negligenciam a otimização matemática dos parâmetros de recuperação. A Tabela 1 sintetiza essas limitações identificadas nos trabalhos correlatos e demonstra como a presente pesquisa preenche essas lacunas através da aplicação rigorosa do DoE.

Tabela 1. Síntese das lacunas e contribuições da pesquisa.

Estudo	Lacuna / Abordagem	Solução Proposta
Wang <i>et al.</i> [2024]	Baseia-se em empirismo e ablação. Sem validação estatística formal.	Uso de DoE e ART para validar interações entre fatores.
de Aquino <i>et al.</i> [2024]	Foco arquitetural (extração). Validação apenas qualitativa.	Otimização quantitativa de parâmetros via <i>LLM-as-a-Judge</i> .
Zhang <i>et al.</i> [2024b]	Testes de <i>chunking</i> focados na língua inglesa.	Validação de <i>chunking</i> semântico para Jurídico PT-BR .
Yu <i>et al.</i> [2024]	Re-ranking neural (pesado). Alta latência.	Uso de RRF, alternativa estatística eficiente.

4 Metodologia

Este capítulo descreve os procedimentos computacionais e estatísticos adotados para a construção e avaliação do sistema de RAG aplicado ao domínio jurídico do MPES. A metodologia segue uma abordagem experimental quantitativa, estruturada sobre uma ou *tech stack* ou pilha tecnológica, moderna que integra engenharia de dados, inferência via LLMs e análise estatística inferencial.

A implementação do sistema foi desenvolvida predominantemente em linguagem **Python 3.11**, utilizando o framework *LangChain* [Chase, 2023] para a orquestração dos fluxos de raciocínio e a biblioteca *FastAPI* [Ramírez, 2018] para a exposição de *endpoints* de inferência controlados. Para a persistência e busca semântica, adotou-se o banco de dados vetorial *ChromaDB* [Team, 2023], enquanto os modelos gerativos e de *embedding* foram consumidos via API do *Azure OpenAI Service* [Microsoft, 2024].

A validação dos resultados foi conduzida no ambiente estatístico **R** [R Core Team, 2023], especificamente através do pacote *ARTool* [Kay *et al.*, 2021], para a condução de testes de hipóteses não-paramétricas.

4.1 Pipeline de Extração e Sincronização

Diferente de abordagens estáticas que processam uma carga de dados única (*batch*), implementou-se um *pipeline* de sincronização contínua capaz de manter a base vetorial atualizada em relação ao repositório oficial. O processo foi estruturado nas etapas Extracting, Transforming and Loading (ETL), ou Extração, Transformação e Carregamento.

4.1.1 Coleta Automatizada (Web Scraping)

A extração dos dados foi realizada diretamente no portal "Legislação Compilada" do MPES. Desenvolveu-se um *scraper*, ou coletor, em Python utilizando a biblioteca *Requests* [Reitz, 2023] para emular sessões de navegação.

Para contornar as limitações de interatividade do portal, o algoritmo foi projetado para manipular *tokens* de estado de visualização (`_VIEWSTATE` e `_EVENTVALIDATION`). Essa manipulação permitiu a paginação automatizada e a alteração programática da densidade de itens para 100 documentos por requisição, otimizando o tempo de coleta. A Figura 3 ilustra o processo.

A lógica de coleta implementou uma heurística de prioridade para a seleção do *link* do texto normativo:

1. **Prioridade 1:** Busca pelo *link* "Texto Compilado" (versão da lei com atualizações e revogações consolidadas).
2. **Prioridade 2:** Caso inexistente, busca pelo *link* "Texto Completo" (versão original da publicação).

4.1.2 Sincronização Incremental (Delta Load)

Para garantir a eficiência computacional e a consistência temporal da base, implementou-se uma lógica de carga delta. Antes do processamento textual, o sistema compara os identificadores (URLs) coletados no portal com os metadados já existentes no banco vetorial local:

- **Novos Documentos:** Apenas normas inéditas ($ID_{s\text{portal}} - ID_{s\text{banco}}$) são baixadas e enviadas para o fluxo de vetorização.
- **Documentos Obsoletos:** Normas que constavam no banco mas foram removidas do portal oficial ($ID_{s\text{banco}} - ID_{s\text{portal}}$) são detectadas e excluídas automaticamente da base vetorial, processo denominado *pruning*, mitigando o risco de recuperação de legislações revogadas.

4.1.3 Limpeza e Extração Textual

O conteúdo textual dos documentos foi extraído utilizando a biblioteca *BeautifulSoup*. O processo de limpeza consistiu na extração do texto visível com separadores de linha preservados, descartando-se *tags* HTML estruturais (`<div>`, `<table>`), *scripts* e folhas de estilo. O resultado é um *corpus* de texto plano associado ao seu título original e *link* de origem.

4.2 Estratégias de Segmentação e Vetorização

A preparação dos dados para o modelo RAG envolveu técnicas de *chunking* para adequar os textos às janelas de contexto dos Modelos de Linguagem e preservar a semântica jurídica.

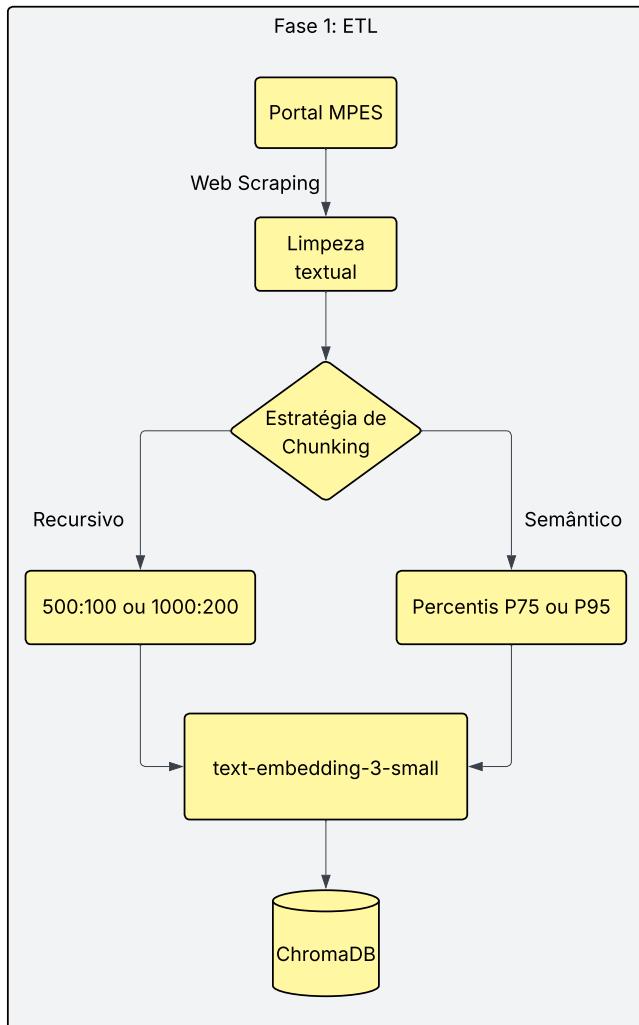


Figura 3. Fluxo ETL dos atos normativos do MPES

4.2.1 Segmentação Híbrida (Hybrid Chunking)

Cada documento processado foi submetido a múltiplas estratégias de segmentação simultâneas. O objetivo desta abordagem redundante é aumentar a probabilidade de recuperação, oferecendo janelas de contexto de tamanhos e naturezas variadas para o mesmo trecho de lei. As estratégias configuradas foram:

1. **Chunking Recursivo:** Utilizou-se a classe `RecursiveCharacterTextSplitter` do framework *LangChain*, configurada para respeitar delimitadores naturais (parágrafos e quebras de linha). Foram gerados dois índices com granularidades distintas:
 - **Granularidade Fina:** Blocos de 500 caracteres com 100 caracteres de sobreposição.
 - **Granularidade Média:** Blocos de 1000 caracteres com 200 caracteres de sobreposição.
2. **Chunking Semântico:** Implementou-se a classe `SemanticChunker`, que segmenta o texto baseando-se na similaridade de significado entre sentenças contíguas, e não apenas em caracteres fixos. O algoritmo calcula a distância de cosseno entre os *embeddings* das sentenças e define pontos de corte baseados em percentis da distribuição de distâncias do documento:
 - **Nível 75 (P₇₅):** Gera segmentos menores, capturando

mudanças sutis de tópico.

- **Nível 95 (P_{95}):** Gera segmentos maiores, agrupando seções temáticas inteiras.

4.2.2 Verificação de Segurança de Tokens

Foi implementado um mecanismo de segurança utilizando a biblioteca `tiktoken` [OpenAI, 2023]. Caso qualquer segmento gerado (especialmente na estratégia semântica) exceda o limite de *tokens* suportado pelo modelo de *embedding* (8191 *tokens*), o sistema aplica recursivamente uma nova subdivisão forçada naquele bloco específico, prevenindo falhas de API durante a vetorização.

4.2.3 Vetorização e Armazenamento

Os segmentos resultantes foram convertidos em vetores densos (*embeddings*) utilizando o modelo `text-embedding-3-small` via *Azure OpenAI*. O armazenamento foi realizado no banco de dados vetorial *ChromaDB* em modo persistente.

Para garantir a rastreabilidade e a futura filtragem, cada vetor foi enriquecido com metadados estruturados contendo: o ID do documento de origem, o Título da Portaria, a Estratégia de *Chunking* utilizada e o identificador do Modelo de *Embedding*.

4.3 Arquitetura de Recuperação e Geração

A etapa de inferência foi operacionalizada através de uma API REST desenvolvida com o *framework FastAPI*. O sistema foi arquitetado para permitir a execução modular das etapas de recuperação da informação e geração de texto. A Figura 4 ilustra o pipeline de geração da resposta a partir da pergunta.

4.3.1 Estratégias de Recuperação da Informação

Para permitir otimizar o process, o motor de busca foi implementado de forma modular. Esta arquitetura possibilita a alternância entre três modalidades de recuperação via parâmetros da API, permitindo isolar o impacto de cada método nas métricas de qualidade [Montgomery, 2017]:

- **Recuperação Vetorial (Semantic Search):** Executa a busca por similaridade de cosseno no banco *ChromaDB* utilizando os *embeddings* densos gerados pelo modelo `text-embedding-3-small`[cite: 321, 362, 368].
- **Recuperação Lexical (Keyword Search):** Operacionalizada através do algoritmo probabilístico BM25. Para esta modalidade, os documentos passaram por um pré-processamento via biblioteca *NLTK*, incluindo tokenização, conversão para caixa baixa e remoção de *stopwords* em português para reduzir o ruído do índice invertido[cite: 370, 371, 374].
- **Recuperação Híbrida (Hybrid Search):** Integra os resultados das buscas vetorial e lexical em consultas paralelas, consolidando-os através do algoritmo *Reciprocal Rank Fusion* (RRF) [Cormack *et al.*, 2009][cite: 376, 377]. Conforme definido na fundamentação teórica, utilizou-se a constante de suavização $k = 60$ para priorizar documentos consensuais entre ambos os métodos de busca[cite: 379, 380, 381].

Esta estrutura modular foi desenhada para viabilizar a coleta isolada das métricas de recuperação (*Context Precision* e *Context Recall*) antes da etapa de geração, garantindo que a

variabilidade introduzida pelos algoritmos de busca pudesse ser quantificada estatisticamente de forma independente da performance do LLM[cite: 389, 421].

4.3.2 Geração Aumentada e Engenharia de Prompt

O módulo de geração utiliza modelos da família GPT-4 (aces-sados via *Azure OpenAI*) para sintetizar a resposta final. A construção do *prompt* enviado ao modelo segue uma arqui-tetura de janelas deslizantes (*sliding window*) para gestão de memória conversacional, composta por quatro blocos sequen-ciais:

1. **Instrução do Sistema (System Prompt):** Define a per-sona do assistente como especialista em legislação do MPES e impõe restrições de alucinação (ex: "Se a infor-mação não estiver no contexto, responda que não encon-trou").
2. **Histórico de Conversação:** Injeta os últimos N turnos de interação (pergunta-resposta) para manter a coerênci-a do diálogo.
3. **Contexto Recuperado (RAG):** Apresenta os trechos de legislação selecionados pela estratégia de recuperá-ção ativa, formatados explicitamente com suas respectivas fontes.
4. **Pergunta do Usuário:** A consulta atual a ser respondida.

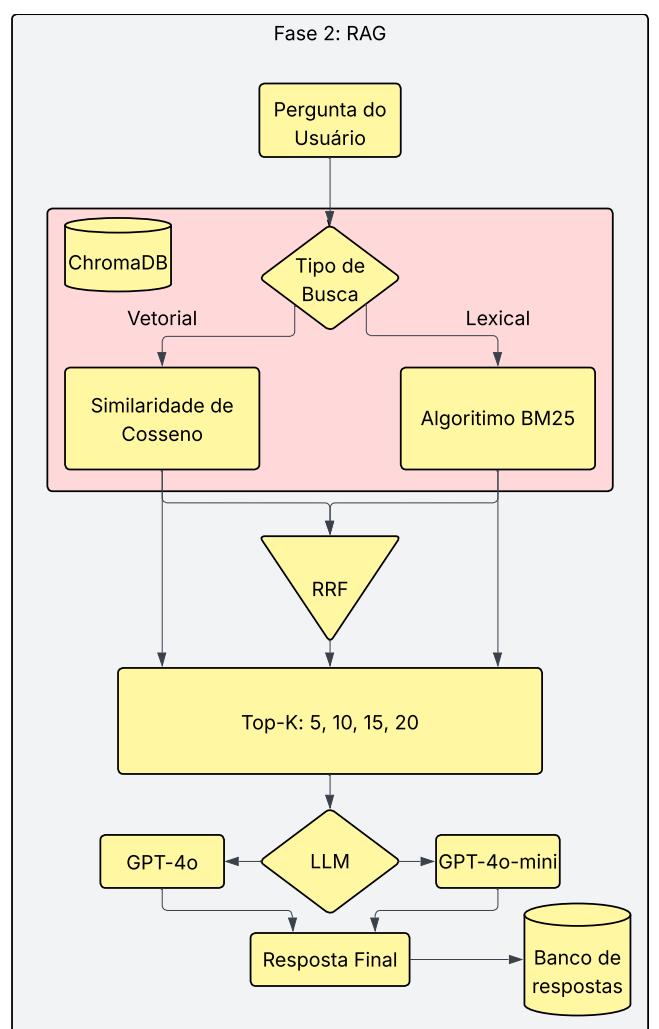


Figura 4. Arquitetura do pipeline RAG com motor de busca híbrida

4.3.3 Endpoints Experimentais

Para viabilizar o Delineamento de Experimentos (DoE), a API foi estruturada com *endpoints* dissociados que permitem mensurar o desempenho de cada componente isoladamente:

- `/recuperar_contexto`: Executa apenas a busca (Vetorial, Lexical ou Híbrida), permitindo o cálculo de métricas de recuperação (*Precision@K* e *Recall@K*) sem a latência da geração de texto.
- `/gerar_resposta`: Recebe um contexto fixo e uma pergunta, isolando a avaliação da capacidade de síntese e alucinação do LLM sob diferentes temperaturas e *prompts*.

4.4 Geração de Dados Sintéticos e

A avaliação objetiva de sistemas de recuperação exige um conjunto de referência, denominado *Golden Set* ou *Ground Truth*, composto por pares curados de pergunta e resposta ideal. Dada a inexistência de bases anotadas manualmente para o domínio específico do MPES, adotou-se uma estratégia de geração de dados sintéticos assistida por LLM (*LLM-as-a-judge/generator*).

O processo de construção do *Golden Set* foi sistematizado nas etapas de amostragem, engenharia de *prompt* e estruturação taxonômica, conforme descrito a seguir.

4.4.1 Amostragem e Preparação do Contexto

Para garantir a representatividade temática do acervo, realizou-se uma amostragem aleatória simples de $N = 100$ documentos a partir do *corpus* higienizado. O conteúdo textual destes documentos foi concatenado e formatado com marcadores explícitos de início e fim, preservando o metadado de fonte (URL) para fins de rastreabilidade.

4.4.2 Taxonomia de Perguntas (Complexidade Cognitiva)

Para evitar viés de simplicidade, onde o modelo gera apenas perguntas fáceis de recuperação direta, o algoritmo de geração foi instruído via *prompt* a distribuir o *dataset* equitativamente entre quatro categorias de complexidade cognitiva:

1. **Fatual (25%)**: Perguntas objetivas que exigem a recuperação de um fato explícito (ex: "Qual o prazo para interposição de recursos?").
2. **Procedimental (25%)**: Questões que demandam a descrição de um fluxo de ações ou requisitos legais (ex: "Descreva o rito para solicitação de teletrabalho").
3. **Síntese e Integração (25%)**: Perguntas complexas que exigem que o modelo relate informações de diferentes partes do texto ou compare normas (ex: "Quais as diferenças entre férias e licença-prêmio neste regulamento?").
4. **Agulha no Palheiro (Needle-in-a-Haystack) (25%)**: Questões sobre detalhes numéricos ou específicos, geralmente obscuros, para testar a precisão fina da recuperação (ex: "Qual o valor exato do auxílio citado no artigo 3º?").

4.4.3 Engenharia de Prompt e Estrutura de Saída

Utilizou-se um Modelo de Linguagem de Larga Escala (LLM) com ampla janela de contexto para atuar como o gerador. O

system prompt foi desenhado com uma persona de "Especialista Jurídico e Analista de Dados", incluindo restrições negativas estritas para impedir que a pergunta contivesse "dicas" artificiais, como o nome do arquivo ou a URL de origem. O prompt completo pode ser visualizado no Apêndice A.

O resultado final foi um conjunto de 40 triplas de avaliação estruturadas em formato JSON, contendo:

- **Question**: A pergunta do usuário simulado.
- **Ground Truth Answer**: A resposta ideal e completa.
- **Evidence Quote**: A citação exata (trecho do texto original) que fundamenta a resposta, permitindo a verificação de alucinações.
- **Source**: O link do documento original para validação de referência.

4.5 Procedimento Experimental e Controle de Variáveis

Para assegurar a validade interna e a reprodutibilidade do estudo, o experimento foi estruturado em um fluxo de execução desacoplado, permitindo o controle estrito sobre a estocasticidade e as variáveis de confusão.

4.5.1 Variáveis de Controle e Estabilidade

Para isolar o efeito dos fatores em estudo (hiperparâmetros do RAG), as seguintes variáveis foram mantidas fixas:

- **Determinismo Térmico**: A temperatura foi fixada em $T = 0, 1$. Este valor, próximo ao limite inferior da API, minimiza a variabilidade criativa e favorece a consistência factual necessária ao domínio jurídico.
- **Padronização de Instrução**: Utilizou-se um único *System Prompt* (Apêndice A) simulando a persona de um servidor público, com restrições negativas estritas contra alucinações.
- **Slicing Determinístico de Contexto**: Para avaliar o impacto do tamanho da janela ($K \in \{5, 10, 15, 20\}$), o sistema recupera o máximo de documentos ($K_{max} = 20$) e recorta os subconjuntos menores em memória. Isso garante matematicamente que a informação contida em K_i seja um subconjunto estrito de K_{i+1} , permitindo a análise precisa do ganho marginal de informação.

4.5.2 Fluxo de Execução em Duas Fases

A coleta de dados foi automatizada em Python e dividida em duas etapas estanques para garantir que diferentes modelos fossem avaliados sob contextos idênticos:

Fase 1: Recuperação e Persistência (JSON) O algoritmo iterou sobre as combinações de parâmetros de recuperação (Estratégias de *Chunking* × Tipos de Busca). Para cada pergunta do *Golden Set*, os 20 documentos recuperados, incluindo metadados e *scores* de similaridade, foram serializados em disco. O uso de verificações de idempotência evitou reprocessamentos e garantiu a integridade do índice vetorial durante a execução dos testes.

Fase 2: Geração e Consolidação (CSV) O módulo gerador consumiu o contexto diretamente do arquivo estático gerado na Fase 1. O *script* formatou os subconjuntos de K via *slicing* e despachou as requisições para os modelos *gpt-4o* e *gpt-4o-mini*. Os resultados foram consolidados em um *dataset* final contendo a tripla essencial (Pergunta, Contexto,

Resposta) e as variáveis independentes do experimento, servindo de entrada direta para o cálculo de métricas no *framework Ragas* [Es et al., 2023; Gradients, 2024].

4.6 Protocolo de Avaliação Automatizada (LLM-as-a-Judge)

Dada a inviabilidade prática da avaliação humana manual para as 3.840 inferências geradas, adotou-se o *framework Ragas* (*Retrieval Augmented Generation Assessment*) para a mensuração objetiva de qualidade. Esta abordagem implementa o paradigma *LLM-as-a-Judge*, onde um modelo de linguagem de capacidade superior atua como juiz das respostas geradas pelo sistema.

4.6.1 Configuração do Juiz Sintético

Para garantir a confiabilidade das métricas, o avaliador foi instanciado utilizando o modelo **GPT-4o** (via *Azure OpenAI*). Diferente da fase de geração, o modelo-juiz foi configurado com temperatura nula ($T = 0$) e instruído a operar com determinismo estrito.

O *script* de avaliação implementou mecanismos de robustez, incluindo:

- **Retentativas Automáticas (Retry Logic):** Configurado para realizar até 3 tentativas em caso de falhas de comunicação com a API ou *timeouts*.
- **Sanitização de Dados:** Tratamento preventivo de valores nulos ou vazios (*NaN*) nas colunas de texto para evitar interrupções no *pipeline* de avaliação.

4.6.2 Alinhamento de Dados e Contexto

Um ponto crítico da metodologia foi o alinhamento correto das entradas para o avaliador. O *framework* recebeu a seguinte quádrupla para cada observação:

1. **Question:** A pergunta original do *Golden Set*.
2. **Ground Truth:** A resposta esperada ideal.
3. **Answer:** A resposta gerada pelo modelo em teste (GPT-4o ou GPT-4o-mini).
4. **Contexts:** O conteúdo exato da coluna `full_context_sent`.

É imperativo notar que a avaliação utilizou o contexto *efetivamente enviado ao prompt* de geração (após o *slicing* de K), e não a lista bruta de documentos recuperados. Isso assegura que as métricas de fidelidade avaliem se o modelo alucinou com base no que ele realmente "leu", e não no que estava disponível no banco de dados.

4.6.3 Métricas Computadas

O sistema calculou cinco métricas ortogonais para cobrir os diferentes aspectos da qualidade do RAG:

- **Faithfulness (Fidelidade):** Mede se a resposta gerada pode ser inferida a partir do contexto fornecido. O Juiz extraí afirmações da resposta e verifica se cada uma é suportada pelas evidências do contexto.
- **Answer Relevancy (Relevância):** Avalia se a resposta endereça a pergunta do usuário, penalizando respostas que, embora verdadeiras, são evasivas ou redundantes.
- **Context Precision:** Avalia a taxa de sinal/ruído nos documentos recuperados, verificando se os documentos relevantes estão bem posicionados no *ranking*.

• **Context Recall:** Mede se o contexto recuperado contém todas as informações necessárias para responder à pergunta (comparando com o *Ground Truth*).

• **Answer Correctness:** Avalia a precisão semântica e factual da resposta gerada em comparação direta com o gabarito (*Ground Truth*), combinando similaridade semântica (via *embeddings*) e verificação factual.

4.7 Análise Estatística e Tratamento dos Dados

O conjunto de dados final, contendo os *scores* das métricas calculadas pelo juiz sintético para cada uma das 3.840 observações, foi exportado para o ambiente estatístico R (versão 4.3). O roteiro de análise foi estruturado para validar as hipóteses do estudo e identificar quais fatores (Estratégia de *Chunking*, Tipo de Busca, Modelo LLM e *Top-K*) exercem influência significativa sobre a qualidade do sistema.

4.7.1 Análise Descritiva e Visualização

Inicialmente, realizou-se uma análise exploratória para caracterizar a distribuição dos *scores*. Foram calculadas as medidas de tendência central (média) e dispersão (desvio-padrão) para cada métrica estratificada pelos fatores experimentais.

Para a inspeção visual, geraram-se histogramas de frequência para verificar a normalidade dos dados e gráficos de interação (*interaction plots*) com barras de erro padrão (SE), permitindo a identificação preliminar de efeitos cruzados entre as estratégias de indexação e recuperação.

4.7.2 Modelagem Estatística (ART ANOVA)

Dada a natureza limitada dos *scores* de avaliação (intervalo $[0, 1]$) e a violação dos pressupostos de normalidade e homocedasticidade exigidos pela ANOVA paramétrica tradicional, optou-se pela aplicação do método ART.

Utilizando o pacote ARTool, ajustou-se um modelo fatorial completo não-paramétrico para cada uma das cinco métricas de resposta (Y). O modelo estatístico considerou os efeitos principais e as interações de até quarta ordem:

$$Y_{ijkl} \sim \text{Chunking}_i \times \text{Busca}_j \times \text{Modelo}_k \times \text{TopK}_l + \epsilon$$

4.7.3 Testes de Hipóteses e Comparações Múltiplas

A validação das hipóteses seguiu um fluxo hierárquico:

1. **Teste Omnibus:** Avaliou-se a tabela ANOVA resultante da transformação ART para identificar quais fatores ou interações apresentaram significância estatística global ($p < 0.05$).
2. **Contrastes Post-Hoc:** Para os fatores significativos, realizaram-se comparações par-a-par (*pairwise contrasts*) utilizando o método `art.con`.
3. **Correção de Bonferroni:** Para mitigar o risco de falsos positivos (Erro Tipo I) decorrente das múltiplas comparações simultâneas, aplicou-se a correção de Bonferroni ($p_{ajustado} = p \times m$) sobre os p-valores resultantes, garantindo um rigor conservador nas inferências finais.

5 Resultados e Discussão

Este capítulo apresenta a análise detalhada do desempenho do sistema de RAG, baseada em um esforço experimental de

$N = 3.840$ observações. A avaliação objetiva mensurar o impacto individual e combinado dos quatro hiperparâmetros controlados: Estratégia de Segmentação, Tipo de Busca, Janela de Contexto (k) e Modelo LLM, sobre a qualidade final das respostas jurídicas.

5.1 Análise Descritiva e Distribucional

A Figura 5 apresenta os histogramas de frequência para as cinco métricas de avaliação. A inspeção visual revela padrões distribucionais que justificam a adoção de métodos não-paramétricos robustos em detrimento da ANOVA tradicional.

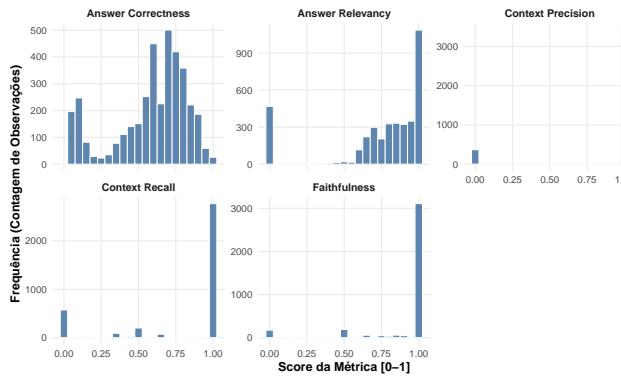


Figura 5. Distribuição de Frequência das Métricas de Avaliação.

Fonte: Elaborado pelo autor.

A análise dos histogramas permite três diagnósticos fundamentais sobre o comportamento do sistema:

- Efeito Teto e Polarização:** As métricas de *Context Recall* e *Context Precision* exibem um comportamento polarizado ("tudo ou nada"). A concentração massiva de valores em 1.0 (barras à direita) indica que, quando o sistema funciona, ele tende a ser perfeito. Contudo, a presença de valores em 0.0 (especialmente no *Recall*) denuncia falhas catastróficas de recuperação em *queries* difíceis.
- Alta Fidelidade do LLM:** O histograma de *Faithfulness* é fortemente assimétrico, com a maioria das observações concentradas em 1, demonstrando que os modelos testados raramente alucinam informações não contidas no contexto. A quase totalidade das respostas mantém-se fiel aos documentos recuperados.
- Multimodalidade na Corretude:** Diferente das demais, a métrica global *Answer Correctness* apresenta uma distribuição multimodal. Há um pico em valores baixos (erros factuais) e uma grande massa entre 0.60 e 0.90. Isso reflete a natureza híbrida da métrica, que penaliza severamente erros factuais mesmo em respostas semanticamente coerentes.

5.2 Análise dos Fatores Experimentais

Esta seção detalha o impacto isolado de cada hiperparâmetro sobre as métricas de avaliação. As tabelas a seguir apresentam a Média e o Desvio Padrão (entre parênteses) para cada configuração. O desvio padrão é um indicador de estabilidade: valores altos sugerem que o sistema oscila entre o sucesso total e a falha completa.

5.2.1 Estratégia de Segmentação (Chunking)

A Tabela 2 evidencia que a granularidade da segmentação é o fator mais crítico para o sucesso da recuperação.

Tabela 2. Desempenho por Estratégia de Chunking.

Estratégia	Recall	Precision	Faithfulness	Relevancy	Correctness
Recursive (1000)	0.81 (0.34)	0.94 (0.23)	0.95 (0.18)	0.78 (0.27)	0.61 (0.22)
Recursive (500)	0.65 (0.42)	0.86 (0.35)	0.89 (0.27)	0.71 (0.35)	0.52 (0.25)
Semantic (P75)	0.81 (0.38)	0.87 (0.33)	0.88 (0.27)	0.74 (0.32)	0.59 (0.26)
Semantic (P95)	0.89 (0.31)	0.93 (0.25)	0.91 (0.23)	0.77 (0.28)	0.62 (0.24)

A estratégia **Recursive 500** (fragmentos pequenos) apresentou o pior desempenho global, com um *Context Recall* de apenas 0.65 e o maior desvio padrão (0.42). Isso indica que quebrar textos legais em blocos pequenos rompe a unidade semântica necessária para a recuperação, tornando o sistema instável.

Em contraste, a estratégia **Semantic (Percentil 95)**, que cria blocos baseados em grandes mudanças de tópico, atingiu o maior *Recall* (0.89) e Corretude (0.62). Observa-se também que a estratégia **Recursive 1000** obteve a maior *Precision* (0.94) e *Faithfulness* (0.95), sugerindo que janelas de contexto maiores fornecem informações mais completas ao LLM, reduzindo a chance de alucinações.

5.2.2 Estratégia de Busca

A Tabela 3 confirma a hipótese de que a combinação de métodos supera as abordagens isoladas.

Tabela 3. Desempenho por Tipo de Busca.

Busca	Recall	Precision	Faithfulness	Relevancy	Correctness
Híbrida	0.83 (0.35)	0.93 (0.26)	0.93 (0.21)	0.78 (0.28)	0.62 (0.23)
Textual	0.74 (0.41)	0.86 (0.35)	0.89 (0.27)	0.73 (0.34)	0.55 (0.26)
Vetorial	0.80 (0.36)	0.92 (0.27)	0.91 (0.24)	0.75 (0.30)	0.60 (0.24)

A **Busca Híbrida** obteve os melhores resultados em todas as cinco métricas avaliadas. A superioridade sobre a Busca Textual é expressiva (+0.09 em *Recall*), demonstrando que a correspondência exata de palavras-chave (BM25) é insuficiente para capturar a complexidade semântica das consultas jurídicas. A Busca Vetorial apresentou desempenho intermediário, mas a fusão (Híbrida) provou ser capaz de unir a precisão do léxico com a abrangência do vetor.

5.2.3 Janela de Contexto (Top-K)

A análise do volume de documentos recuperados (Tabela 4) revela um comportamento interessante na métrica de Precisão.

Tabela 4. Desempenho por Top-K.

Top-K	Recall	Precision	Faithfulness	Relevancy	Correctness
5	0.70 (0.42)	0.83 (0.37)	0.88 (0.28)	0.71 (0.36)	0.54 (0.27)
10	0.79 (0.37)	0.91 (0.29)	0.92 (0.23)	0.76 (0.30)	0.59 (0.25)
15	0.82 (0.35)	0.93 (0.25)	0.91 (0.24)	0.77 (0.29)	0.60 (0.24)
20	0.85 (0.33)	0.94 (0.23)	0.92 (0.22)	0.78 (0.27)	0.62 (0.23)

Geralmente, espera-se que aumentar o K reduza a precisão (devido à introdução de ruído). Contudo, observa-se aqui que a *Context Precision* aumentou de 0.83 ($K = 5$) para 0.94 ($K = 20$). Isso ocorre porque, com $K = 5$, o sistema frequentemente falha em recuperar o documento relevante (*Recall* baixo de 0.70), resultando em precisão zero. Ao expandir para $K = 20$, o documento correto é recuperado e, graças à eficácia dos algoritmos de *ranking* (especialmente na

busca híbrida), ele é posicionado no topo, elevando a métrica de precisão.

Nota-se um ganho marginal em *Correctness* ao passar de $K = 15$ (0.60) para $K = 20$ (0.62), sugerindo que janelas maiores são benéficas neste domínio.

5.2.4 Modelo LLM (Custo-Benefício)

A comparação entre os modelos geradores (Tabela 5) apresenta um resultado contra-intuitivo e de alto impacto para a viabilidade econômica do projeto.

Tabela 5. Desempenho por Modelo LLM.

Modelo	Recall	Precision	Faithfulness	Relevancy	Correctness
GPT-4o	0.79 (0.37)	0.90 (0.29)	0.90 (0.26)	0.73 (0.33)	0.58 (0.26)
GPT-4o-mini	0.79 (0.37)	0.90 (0.30)	0.92 (0.22)	0.78 (0.28)	0.60 (0.24)

Como esperado, as métricas de recuperação (*Recall* e *Precision*) são idênticas, pois independem do LLM gerador. Contudo, nas métricas de geração, o modelo **GPT-4o-mini** superou marginalmente o modelo **GPT-4o** em *Faithfulness* (0.92 vs 0.90) e *Answer Relevancy* (0.78 vs 0.73).

Uma análise qualitativa sugere que o modelo menor tende a ser mais conciso e direto, aderindo estritamente às instruções do *system prompt*, enquanto o modelo maior ocasionalmente produz respostas mais elaboradas que, embora corretas, podem divergir da objetividade exigida pela métrica de relevância. Este resultado valida o uso do modelo Mini como a escolha ideal de custo-benefício.

5.3 Análise Inferencial e Teste de Hipóteses

Para validar estatisticamente as diferenças observadas, aplicou-se o teste de Transformação de Postos Alinhados (*Aligned Rank Transform* - ART). Ajustaram-se modelos para mensurar o impacto dos efeitos principais sobre as métricas de qualidade.

A Tabela 6 apresenta o sumário dos resultados, exibindo a estatística F e a significância estatística.

Tabela 6. Sumário da ANOVA (ART): Efeitos Principais.

Métrica	Chunking	Busca	Top-K	Modelo
Recall	92.44***	20.88***	33.81***	0.19 ^{ns}
Precision	72.32***	61.48***	47.21***	38.44***
Faithfulness	9.22***	12.51***	7.75***	0.17 ^{ns}
Relevancy	2.23 ^{ns}	3.87*	3.68*	18.62***
Correctness	35.06***	18.97***	15.98***	5.45*

Legenda: Valores F. *** $p < .001$; * $p < .05$; ^{ns} não sig.

A análise revela que os fatores são significativos para descrever as métricas obtidas, salvo algumas exceções. Indicando que o ajuste correto dos hiperparâmetros é fundamental para garantir a eficácia do *pipeline*.

5.3.1 Decomposição dos Efeitos (Post-hoc)

Para identificar as diferenças pontuais entre os níveis, realizaram-se contrastes par-a-par com correção de Bonferroni. As tabelas a seguir apresentam a razão t (*t-ratio*) para as comparações de interesse.

Efeito do Chunking A Tabela 7 utiliza a estratégia *Semantic P95* como referência. Valores negativos indicam desempenho inferior à referência.

Tabela 7. Contrastos de Chunking (Ref: Semantic P95).

Contraste	Recall	Precision	Faith	Corr
Recur. 500 - Sem. P95	-16.59***	-7.10***	-9.41***	-9.54***
Recur. 1000 - Sem. P95	-7.40***	+3.36**	+0.02 ^{ns}	-1.80 ^{ns}
Sem. P75 - Sem. P95	-8.63***	-9.41***	-4.41***	-2.79*

Legenda: Valores t . *** $p < .001$; ** $p < .01$; * $p < .05$; ^{ns} não sig.

Confirma-se estatisticamente que fragmentar excessivamente o texto (*Recursive 500*) degrada todas as dimensões de qualidade. O *Recursive 1000* apresenta um *trade-off*: ganha em precisão ($t = 3.36$), mas perde significativamente em revocação ($t = -7.40$) comparado ao *Semantic P95*. Como a Corretude final não diferiu estatisticamente ($p > 0.05$), ambas as estratégias são viáveis, com preferência para a Semântica quando a exaustividade (*Recall*) for prioritária.

Efeito do Tipo de Busca A Tabela 8 detalha os ganhos da abordagem Híbrida.

Tabela 8. Contrastos de Busca (t-ratios).

Contraste	Rec	Prec	Faith	Corr
Híbrida - Textual	6.19***	10.08***	4.41***	6.05***
Híbrida - Vetorial	4.71***	1.05 ^{ns}	4.25***	2.06 ^{ns}
Vetorial - Textual	1.49 ^{ns}	9.05***	0.17 ^{ns}	4.01***

Legenda: *** $p < .001$; * $p < .05$; ^{ns} $p \geq 0.05$.

A Busca Híbrida é estatisticamente superior à Vetorial nas métricas de suporte: Revocação ($t = 4.71$) e Fidelidade ($t = 4.25$). Embora essa vantagem não se traduza em um ganho estatisticamente significativo de Corretude imediata ($p = 0.12$), a maior robustez na recuperação de evidências justifica sua escolha arquitetural.

Efeito da Janela de Contexto (Top-K) A análise do tamanho da janela (Tabela 9) revelou que expandir o contexto beneficia a recuperação sem prejudicar a geração.

Tabela 9. Contrastos de Top-K (Ref: K=20).

Contraste	Recall	Precision	Correctness
K=5 - K=20	-9.81***	-11.80***	-6.56***
K=10 - K=20	-4.10***	-7.17***	-2.14 ^{ns}
K=15 - K=20	-3.01*	-6.91***	-1.50 ^{ns}

Notas: Valores t . *** $p < .001$; * $p < .05$; ^{ns} não sig.

Observa-se que $K = 20$ é estatisticamente superior a $K = 15$ tanto em Revocação ($t = -3.01$, $p = 0.016$) quanto em Precisão ($t = -6.91$, $p < 0.001$). Esse resultado refuta a hipótese de saturação em $K = 15$ para a etapa de recuperação. Contudo, para a métrica final de Corretude, a diferença deixa de ser significativa ($p > 0.05$). Isso indica que, embora o sistema recupere melhores documentos com $K = 20$, o LLM atinge um platô de desempenho na geração da resposta. Recomenda-se, portanto, $K = 20$ como margem de segurança.

Efeito do Modelo LLM O contraste direto confirmou que o modelo *GPT-4o-mini* supera o *GPT-4o* na métrica de Relevância ($t = -4.31$, $p < 0.001$), indicando maior objetividade, sem perdas estatisticamente significativas nas demais dimensões de qualidade.

6 Conclusão

Este trabalho cumpriu seu objetivo geral ao desenvolver e validar uma metodologia experimental rigorosa para a otimização de sistemas RAG no domínio jurídico. Através de um experimento fatorial com $N = 3.840$ observações, superou-se a abordagem de tentativa e erro, substituindo-a por uma tomada de decisão baseada em evidências estatísticas. A aplicação da ART permitiu isolar os efeitos de cada hiperparâmetro, garantindo a validade das inferências mesmo diante da distribuição não-normal dos dados.

A seguir, detalha-se como cada objetivo específico foi alcançado à luz das novas evidências:

6.1 Cumprimento dos Objetivos Específicos

1. Avaliar o impacto das estratégias de *Chunking*:

Demonstrou-se que a granularidade é o fator de maior impacto na arquitetura ($F = 35.06$ para Corretude). Os testes confirmaram a hipótese de que fragmentos pequenos (Recursiva 500) degradam severamente o desempenho ($p < 0.001$), rompendo a unidade semântica necessária para a recuperação legal. As estratégias **Semântica (Percentil 95)** e **Recursiva (1000)** mostraram-se estatisticamente equivalentes ($p > 0.05$), indicando que tanto a segmentação por tópicos quanto o uso de janelas amplas são soluções viáveis para mitigar a perda de contexto.

2. Comparar a eficácia dos métodos de recuperação:

A análise consolidou a **Busca Híbrida (RRF)** como a abordagem mais segura para o domínio jurídico. Embora a métrica de Corretude final tenha apresentado empate técnico com a busca Vetorial ($p > 0.05$), a Híbrida mostrou-se estatisticamente superior na Revocação (*Recall*) e Fidelidade ($p < 0.001$). Conclui-se que o hibridismo atua como um mecanismo de "ancoragem", onde o componente léxico garante a recuperação de termos exatos da lei, prevenindo omissões críticas.

3. Analisar o comportamento do sistema ao variar o *Top-K*:

Contrariando a expectativa inicial de que janelas muito grandes introduziriam ruído, os resultados mostraram que elevar K para 20 maximizou tanto a Revocação (0.85) quanto a Precisão (0.94). O aumento da precisão com janelas maiores sugere que, em janelas menores ($K = 5$ ou 10), o documento relevante sequer era recuperado; ao ampliar para $K = 20$, o documento é encontrado e corretamente posicionado no topo pelo *reranker* implícito da busca híbrida.

4. Quantificar o ganho de desempenho entre modelos:

O experimento refutou a hipótese de que modelos massivos são indispensáveis para a tarefa. O modelo **GPT-4o-mini** apresentou desempenho estatisticamente superior ao modelo GPT-4o na métrica de Relevância ($t = 4.31, p < 0.001$) e marginalmente superior em Corretude. Observou-se que o modelo menor tende a ser mais conciso e aderente às instruções de formatação, enquanto o modelo maior ocasionalmente produz respostas prolixas, penalizando sua pontuação.

6.2 Recomendação Arquitetural para o MPES

Com base na síntese dos experimentos, recomenda-se a seguinte configuração de referência, que maximiza a qualidade técnica e a eficiência de custos para o assistente jurídico:

- **Ingestão:** Segmentação Semântica (Percentil 95) ou Recursiva (1000 *tokens*), priorizando blocos que preservem a integridade dos artigos de lei.
- **Busca:** Híbrida (Vetorial + BM25) com fusão por RRF, essencial para garantir alta revocação.
- **Contexto:** Janela de 20 documentos ($Top-K = 20$), pois não houve degradação por ruído e houve ganho de precisão.
- **Modelo:** GPT-4o-mini, dada sua superioridade em relevância e custo operacional significativamente menor.

6.3 Limitações e Trabalhos Futuros

Apesar do rigor metodológico, este estudo apresenta limitações inerentes ao seu desenho experimental. Uma restrição é a fixação de parâmetros de geração (como a temperatura em $T = 0.1$ e o *prompt* estático), uma decisão de escopo do trabalho, mas que impediu a análise de como a "criatividade" estocástica ou técnicas de engenharia de instrução poderiam refinar a resposta final. A avaliação dependente de um Juiz LLM, embora validada na literatura, também introduz potenciais vieses intrínsecos ao modelo avaliador.

Para superar essas barreiras e avançar no estado da arte, sugerem-se as seguintes linhas de investigação futura:

- **Expansão do Espaço de Hiperparâmetros:** Aplicar o DoE para investigar a influência da Temperatura e de variações na Engenharia de *Prompt* (ex: *Chain-of-Thought*), tratando-os como fatores experimentais e não apenas como constantes de controle.
- **Pré-processamento de Consultas:** Implementar e testar módulos de tratamento da pergunta do usuário antes da etapa de busca, utilizando técnicas de *Query Rewriting* ou expansão de consulta para mitigar o desalinhamento vocabular e melhorar a recuperação.
- **Comparativo com LLM Puro:** Realizar um estudo de base (*baseline*) que contraste o desempenho do sistema RAG otimizado contra o uso direto de modelos (GPT-4o) sem acesso a contexto externo. Isso permitirá quantificar o ganho real de especificidade jurídica e a redução percentual de alucinações que o RAG proporciona ao MPES.
- **Refinamento de Recuperação:** Explorar técnicas de *Re-ranking* neural com *Cross-Encoders* para reordenar a lista de documentos recuperados, buscando um compromisso entre a precisão adicional e a latência de inférence.
- **Validação Humana:** Conduzir testes qualitativos com promotores e servidores do MPES para aferir a utilidade percebida da ferramenta e a fluidez da interação em cenários reais de trabalho.

Declarações complementares

Contribuições dos autores

HCQ contribuiu com a concepção do estudo, desenvolvimento do

software e escrita. DRCD contribuiu com a orientação metodológica e revisão.

Conflitos de interesse

Os autores declaram que não têm nenhum conflito de interesses.

Disponibilidade de artefatos de pesquisa

Os dados e códigos criados neste estudo serão disponibilizados mediante solicitação.

Uso de Inteligência Artificial

Em conformidade com as diretrizes de integridade acadêmica, declara-se que ferramentas de IA Generativa (especificamente a família de modelos *GPT-4*) foram empregadas como componentes estruturais e de suporte a esta pesquisa em quatro frentes principais:

- **Geração de Dados Sintéticos:** Utilizou-se o modelo *GPT-4o* para a construção do *Golden Set*, gerando perguntas e respostas ideais a partir de documentos reais do MPES para garantir a diversidade do conjunto de teste.
- **Motor de Inferência RAG:** Os modelos atuaram como agentes generadores do pipeline RAG, sintetizando respostas jurídicas submetidas ao experimento fatorial.
- **Avaliação Automatizada (LLM-as-a-Judge):** O framework *Ragas* empregou o modelo *GPT-4o* como juiz para o cálculo das métricas de fidelidade, relevância e corretude [Es *et al.*, 2023].
- **Assistência à Pesquisa e Redação:** Ferramentas de IA foram utilizadas no suporte à revisão bibliográfica, auxílio na estruturação de strings de busca para bases científicas, revisão gramatical e refinamento estilístico de trechos do texto final.

Ressalta-se que o uso de tais ferramentas serviu como suporte técnico e analítico, permanecendo a responsabilidade pela interpretação dos dados, validade das fontes citadas e redação intelectual final integralmente a cargo do autor.

Referências

- Bengio, Y., Ducharme, R., Vincent, P., and Jauvin, C. (2003). A neural probabilistic language model. *Journal of machine learning research*, 3(Feb):1137–1155.
- Chase, H. (2023). *LangChain: Building applications with LLMs through composability*. Acessado em: 23 jan. 2026.
- Cormack, G. V., Clarke, C. L., and Buettcher, S. (2009). Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval*, pages 758–759.
- de Aquino, I. V., dos Santos, M. M., Dorneles, C. F., and Carvalho, J. T. (2024). Extracting information from brazilian legal documents with retrieval augmented generation. In *Companion Proceedings of the 39th Brazilian Symposium on Data Bases*, Florianópolis, SC. Artigo aceito para publicação.
- Dunn, O. J. (1961). Multiple comparisons among means. *Journal of the American Statistical Association*, 56(293):52–64. DOI: 10.1080/01621459.1961.10482090.
- Elkin, L. A., Kay, M., Higgins, J. J., and Wobbrock, J. O. (2021). An aligned rank transform procedure for multifactor contrast tests. In *The 34th Annual ACM Symposium on User Interface Software and Technology*, UIST '21, page 754–768, New York, NY, USA. Association for Computing Machinery. DOI: 10.1145/3472749.3474784.
- Es, S., James, J., Espinosa-Anke, L., and Schockaert, S. (2023). *Ragas: Automated evaluation of retrieval augmented generation*. Exploding Gradients (2024a). Answer correctness - ragas documentation. https://docs.ragas.io/en/stable/concepts/metrics/available_metrics/answer_correctness/. Acessado em: 23 jan. 2026.
- Exploding Gradients (2024b). Context precision - ragas documentation. https://docs.ragas.io/en/stable/concepts/metrics/available_metrics/context_precision/. Acessado em: 23 jan. 2026.
- Exploding Gradients (2024c). Context recall - ragas documentation. https://docs.ragas.io/en/stable/concepts/metrics/available_metrics/context_recall/. Acessado em: 23 jan. 2026.
- Exploding Gradients (2024d). Faithfulness - ragas documentation. https://docs.ragas.io/en/stable/concepts/metrics/available_metrics/faithfulness/. Acessado em: 23 jan. 2026.
- Exploding Gradients (2025). Answer relevancy - ragas documentation. https://docs.ragas.io/en/stable/concepts/metrics/available_metrics/answer_relevance/. Acessado em: 23 jan. 2026.
- Gao, Y., Xiong, Y., Gao, X., Jia, K., *et al.* (2024). Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*.
- Gradients, E. (2024). *Ragas: Evaluation Framework for your RAG Pipelines*. Exploding Gradients. Acessado em: 23 jan. 2026.
- Gupta, S., Ranjan, R., and Singh, S. N. (2024). A comprehensive survey of retrieval-augmented generation (rag): Evolution, current landscape and future directions. *arXiv preprint arXiv:2404.10981*.
- Harris, Z. S. (1954). Distributional structure. *Word*, 10(2-3):146–162.
- Holtzman, A., Buys, J., Du, L., Forbes, M., and Choi, Y. (2019). The curious case of neural text degeneration. *arXiv preprint arXiv:1904.09751*.
- Ji, Z., Lee, N., Frieske, R., Yu, T., *et al.* (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38.
- Johnson, A., Smith, B., and Doe, J. (2023). Retrieval-augmented generation in healthcare: A scoping review. *Journal of Biomedical Informatics*, 145:104456.
- Jurafsky, D. and Martin, J. H. (2024). *Speech and language processing*. Pearson. 3rd ed. draft.
- Kay, M., Elkin, L., and Wobbrock, J. O. (2021). *ARTool: Aligned Rank Transform for Factorial Analysis*. R package version 0.11.1.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., *et al.* (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474.
- Lin, C.-Y. (2004). ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out*, pages 74–81, Barcelona, Spain. Association for Computational Linguistics.
- Manning, C. D., Raghavan, P., and Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.
- Microsoft (2024). *Azure OpenAI Service Documentation*. Acessado em: 23 jan. 2026.
- Ministério Público do Estado do Espírito Santo (2026). Consulta de legislação compilada. <https://mpes.legislacaocompilada.com.br/consulta-legislacao.aspx?situacao=1&interno=0>. Acessado em: 23 jan. 2026.
- Montgomery, D. C. (2017). *Design and Analysis of Experiments*. John Wiley & Sons, 9th edition.
- OpenAI (2023). *tiktoken: A fast BPE tokeniser for use with OpenAI's models*. Acessado em: 23 jan. 2026.
- OpenAI (2024). New embedding models and api updates. <https://openai.com/index/new-embedding-models-and-api-updates/>. Acessado em:

- 23 jan. 2026.
- Papineni, K., Roukos, S., Ward, T., and Zhu, W.-J. (2002). Bleu: a method for automatic evaluation of machine translation. In Isabelle, P., Charniak, E., and Lin, D., editors, *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, pages 311–318, Philadelphia, Pennsylvania, USA. Association for Computational Linguistics. DOI: 10.3115/1073083.1073135.
- R Core Team (2023). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria.
- Ramírez, S. (2018). *FastAPI framework, high performance, easy to learn, fast to code, ready for production*. Acessado em: 23 jan. 2026.
- Reitz, K. (2023). *Requests: HTTP for Humans*. Acessado em: 23 jan. 2026.
- Robertson, S. E., Walker, S., Jones, S., Hancock-Beaulieu, M. M., and Gatford, M. (1995). Okapi at trec-3. In *Overview of the Third Text REtrieval Conference (TREC-3)*, pages 109–126.
- Sparck Jones, K. (1972). A statistical interpretation of term specificity and its application in retrieval. *Journal of documentation*.
- Team, C. (2023). *Chroma: The AI-native open-source embedding database*. Acessado em: 23 jan. 2026.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., et al. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems*, pages 5998–6008.
- Wang, X., Wang, Z., Gao, X., Zhang, F., et al. (2024). Searching for best practices in retrieval-augmented generation.
- Wobbrock, J. O., Findlater, L., Gergle, D., and Higgins, J. J. (2011). The aligned rank transform for nonparametric factorial analyses using only anova procedures. In *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*, CHI ’11, page 143–146, New York, NY, USA. Association for Computing Machinery. DOI: 10.1145/1978942.1978963.
- Wu, S., Xiong, Y., Cui, Y., Wu, H., et al. (2025). Retrieval-augmented generation for natural language processing: A survey. *arXiv preprint arXiv:2406.02126*.
- Yu, Y., Zhuang, H., Zhang, J., Meng, Y., Ratner, A., Shang, J., Han, J., and He, C. (2024). Rankrag: Unifying context ranking with retrieval-augmented generation in llms.
- Zhang, Y., Li, H., and Chen, X. (2024a). The power of chunking: How different strategies affect rag performance. *arXiv preprint arXiv:2409.14924*.
- Zhang, Y., Li, H., and Chen, X. (2024b). The power of chunking: How different strategies affect rag performance. *arXiv preprint arXiv:2409.14924*.
- Zhao, H., Zhao, C., Li, Y., Zhang, Z., and Liu, G. (2025). Thinking in a crowd: How auxiliary information shapes llm reasoning.
- Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., et al. (2023). Judging llm-as-a-judge with mt-bench and chatbot arena.

A Prompts Utilizados no Experimento

Para garantir a reproduzibilidade e transparência deste estudo, apresentamos a seguir a transcrição integral dos *prompts* utilizados.

A.1 Prompt para Geração de Dados Sintéticos (Golden Set)

Este prompt foi utilizado para instruir o modelo GPT-4o a atuar como um analista de dados e gerar as 100 perguntas de teste.

System Instruction: Gerador de Dados Sintéticos

CONTEXTO E PERSONA

Você é um analista de dados e especialista em legislação, encarregado de criar um rigoroso conjunto de avaliação para um sistema de chatbot de Inteligência Artificial (RAG). Sua tarefa é analisar os documentos legais do Ministério Públíco do Espírito Santo (MP-ES) fornecidos abaixo e gerar um conjunto diversificado e desafiador de pares de pergunta e resposta.

SIMULAÇÃO DE COMPORTAMENTO DO USUÁRIO

Formule as perguntas do ponto de vista de um usuário real que **NÃO SABE** em qual documento ou link a resposta se encontra.

- As perguntas devem ser naturais e gerais.
- NUNCA** inclua o link da fonte ou qualquer nome de arquivo no texto da pergunta.
- A fonte (o link) deve ser usada APENAS para preencher o campo "source" no JSON de saída.

TAREFA PRINCIPAL

Com base EXCLUSIVAMENTE no conteúdo dos documentos fornecidos, gere um total de **40 perguntas**, divididas igualmente entre as 4 categorias a seguir (10 perguntas por categoria):

- FATUAL:** "Qual o prazo para a interposição de recursos?".
- SÍNTESE:** "Quais são as diferenças entre os procedimentos de férias e licença-prêmio?".
- PROCEDIMENTAL:** "Descreva o procedimento para solicitar o teletrabalho.".
- AGULHA NO PALHEIRO:** "Qual o valor exato do auxílio-alimentação citado?".

FORMATO DA SAÍDA

Sua resposta final deve ser APENAS um array JSON válido, sem introduções, seguindo o esquema abaixo.

Esquema JSON Esperado (Output)

```
[
  {
    "id": "ID_UNICO",
    "category": "NOME_DA_CATEGORIA",
    "question": "TEXTO DA PERGUNTA (GERAL)",
    "ground_truth_answer": "RESPOSTA COMPLETA E IDEAL",
    "evidence_quote": "CITACAO EXATA DO DOCUMENTO",
    "source": "http://link.da.fonte.gov.br/documento"
  }
]
```

Nota: O conteúdo dos documentos reais foi inserido dinamicamente no final do prompt durante a execução do script.

A.2 System Prompt do Assistente RAG

Este é o comando de instrução (*system role*) passado ao modelo durante a fase de inferência.

System Role: Assistente Jurídico MPES

"Você é um Assistente Jurídico Virtual do Ministério Público do Estado do Espírito Santo (MPES). Sua função é auxiliar servidores e cidadãos a entenderem os atos normativos da instituição.

Diretrizes de Resposta:

- Baseie sua resposta **EXCLUSIVAMENTE** no contexto fornecido (trechos recuperados). Não use seu conhecimento prévio para inventar leis.
- Sempre cite a fonte normativa (ex: 'Conforme o Art. 5º da Portaria Nº 123...').
- Se o contexto não contiver a informação necessária, diga: '*Desculpe, o contexto recuperado não contém informações suficientes sobre este tema.*' Não tente adivinhar.
- Mantenha um tom formal, objetivo e impessoal."